

河南大学

科研实验室（平台）面向本科生开放性课题项目

申 请 书

（教师申报版）

项目名称： 网络入侵检测中基于黑盒迁移的
AI 模型对抗攻击研究

指导教师： 杜晓玉

教师工号： 10110049

教师所在学院： 计算机与信息工程学院

填写日期： 2025 年 10 月 23 日

河南大学教务处制

填写说明

一、封面中的项目编号由学校统一编排填写。

二、申请书中第 2 页和第一至第五项的内容，项目申报教师需简要填写，后期带领团队成员完善项目计划书。

三、“项目所属学科”按教育部 2012 年颁布的“普通高等学校本科专业目录”中的法学、教育学、文学、历史学、理学、工学、农学、医学、管理学等 13 个一级学科门类中的一种或多种(跨学科)。

四、所填内容要实事求是、简明清晰、具体可靠。对提供虚假材料或信息数据不实者，将取消申报资格，并承担相应责任。

五、**格式要求：**封面使用小三号字体，表格中使用五号字体，所填写的文字用宋体，数字及其他用 Times New Roman，单倍行距。需签字部分须由相关人员用黑色钢笔或水笔签名。A4 纸双面打印，左侧装订。

项目名称		网络入侵检测中基于黑盒迁移的 AI 模型对抗攻击研究					
项目来源		(√) 指导教师科研项目、() 指导教师自选课题、() 其他					
申报类型		指导教师申报					
项目所属一级学科名称		计算机科学与技术			起止时间(原则上为 1 年)		2025. 11-2026. 10
申请经费(元)		20000			依托实验室(必须省部级及以上实验室)		河南省大数据分析处理重点实验室
指导教师	姓 名	性别	出生年月	学历	职称	所在单位	联系电话
	杜晓玉	女	1979. 11	博士	教授	计算机与信息工程学院	15937828770
	第一指导教师的业务特长与主要学术成果						
	主要从事计算机病毒分析、逆向工程、数据中心网络等领域研究。截止目前指导大学生创新创业项目 11 项, 其中国家级 4 项, 省级 2 项, 校级 5 项, 获得授权专利 9 项, 软件著作权 2 项, 主持在研国家自然科学基金 1 项, 省级项目 3 项, 发表 SCI、EI 论文四十余篇。 一、主要教学成果 1. 教学获奖情况 [1] 2025 年, 河南省本科高校教师课堂教学创新大赛 一等奖; [2] 2025 年, 河南省本科高校教学技能大赛, 一等奖; [3] 2024 年, 河南大学教学成果奖, 二等奖; [4] 2023 年, 河南省本科高校教学技能大赛, 二等奖; [5] 2022 年, 河南省本科高校教学技能大赛, 二等奖; [6] 2017 年, 河南大学教学质量竞赛, 特等奖; [7] 2018 年, 河南大学教学质量竞赛, 特等奖; [8] 2019 年, 教育部在线教育研究中心 2019 年“智慧教学之星”荣誉称号; [9] 2019 年, 第四届河南省高等学校信息安全对抗大赛 优秀指导教师; [10] 2018 年, 信阳杯网络安全对抗技术挑战赛 三等奖 指导教师; [11] 2019 年, 新华三杯全国大学生数字技术大赛, 优秀指导教师; [12] 2019 年, “金盾信安杯”网络安全大赛线上挑战赛, 优秀指导老师; [13] 2019 年, 网络安全尖峰训练营, 优秀指导老师; [14] 2019 年, 教育部在线教育研究中心 智慧教学之星; [15] 2020 年, 第五届河南省高等学校信息安全对抗大赛 优秀指导教师; [16] 2022 年, “两贯通六着重” 学生创新能力的培养与实践, 河南省高等教育教学						

	成果奖二等奖，第 6 名； 2. 教学改革项目 [1] 2017 电路实验课的改革与实践，河南大学教务处，主持，结项； [2] 2023 年，新工科背景下信息安全专业建设规划和课程体系研究，河南大学，主持，结项； [3] 2021 年，“两贯通六着重”学生创新能力的培养与实践，河南省教育厅，参与； [4] 2021 年，河南省线下一流本科课程《计算机组成原理》，主持； [5] 2021 年，河南省新工科（信息安全）实习实践基地，主持； 3. 教改论文 [1] 杜晓玉，吴永辉、李会萍，大学电子类基础实验教学模式研究[J]，实验室科学，2016.19（4）：153-155 [2] 杜晓玉,孔庆梅,李辉.共射极放大电路失真问题分析[J].实验科学与技术,2017,15(04):11-13+26. [3] 杜晓玉,李辉,张磊,周毅.新工科的信息安全专业建设规划研究[J].计算机时代,2022(09):127-131.DOI:10.16644/j.cnki.cn33-1094/tp.2022.09.029. 4. 大学生创新创业床训练项目 [1] 2024 年，智慧交通的隐私保护和可信研究，校级，指导教师：杜晓玉； [2] 2023 年，基于人体骨骼框架识别的坐姿矫正系统，省级，指导教师：杜晓玉； [3] 2023 年，基于深度学习的图像处理与传感器网络的小麦疾病综合测评系统，指导老师：韩志杰，杜晓玉； [4] 2017 年，基于无线通信的信息交互系统，国家级，指导教师：杜晓玉； [5] 2017 年，基于 WSN 的环境监测系统设计与实现，国家级，指导教师：杜晓玉 [6] 2018 年，基于安卓的学生考勤管理系统，省级，指导教师：杜晓玉； [7] 2019 年，WannaCry 病毒分析破解专杀工具设计，校级，指导教师：杜晓玉； [8] 2020 年，太阳能供电小型无线水环境监测系统，国家级，指导教师：杜晓玉； [9] 2021 年，基于 Python 的网站安全评估与修复系统，校级，指导教师：杜晓玉； [10]2022 年，车联网入侵检测，校级，指导教师：杜晓玉； [11]2022 年，基于雷达与热成像的行为特征识别与预警系统，校级，指导教师：杜晓玉； 5. 教材 [1] 杜晓玉、房彩丽、王娟，计算机组成原理课程教学指导[M]，河南大学出版社，2022，郑州； [2] 钟诚、宋香梅、葛丽娜、杜晓玉，信息安全概论[M]，武汉理工大学出版社，
--	--

	2025, 武汉; 二、主要科研成果 1. 主持及参与项目 [1]水下传感网动态覆盖策略及其抗毁机制的研究(61701170), 2017, 国家自然科学基金项目, 国家自然科学基金委员会, 结项, 主持 [2] 基于信息相关性的传感器网络数据聚合技术研究(61300239), 2017, 国家自然科学基金项目, 国家自然科学基金委员会, 结项, 第五 [3] 基于哈密顿分析的混合数据中心网络可靠性研究(222102210052), 河南省重点研发与推广专项(科技攻关), 结项, 主持 [4] 面向水环境监测的无线传感器网络三维感知模型及覆盖机制研究(CXZZ12_0481), 2015, 江苏省教育厅, 江苏省普通高校研究生科研创新计划, 结项, 主持 [5] 基于三维水体监测的无线传感网覆盖研究(17A120007), 河南省教育厅科学技术研究重点项目, 结项, 主持 [6] 面向水环境监测的传感网三维覆盖及部署研究(2013YBZR004), 河南大学科研基金项目, 结项, 主持 2.部分发表论文 [1] Xiaoyu Du, Song Tao and Ke Yuan*, A blockchain authentication scheme for UAV-aided fog computing[J], Complex & Intelligent Systems, 2024.4:1689-1702, (SCI 2区) [2] Yuan, K., Cao, H., Zhang, S. Xiaoyu D*, et al. A tamper-resistant timed secure data transmission protocol based on smart contract[J]. Sci Rep 13, 11510 (2023). (SCI 2区) [3] Qingfang Zhang, Xiaoyu Du*, Jie Li and Zhijie Han, Design and analysis of wireless data center network topology HCDCN based on VLC[J], Journal of Cloud Computing:Advances, Systems and Applications, (SCI 3区) [4] Du X, Cheng C , Han Z ,et al. Hamiltonian properties of HCN and BCN networks [J].Journal of Supercomputing, 2023, 79(2). (SCI 3区) [5] Du X , Li Y , Zhou S* ,et al. ATS-LIA: A lightweight mutual authentication based on adaptive trust strategy in flying ad-hoc networks[J].Peer-to-Peer Networking and Applications, 2022. (SCI 3区) . [6] 杜晓玉,孙力娟,等.异构无线传感器网络覆盖优化算法[J], 电子与信息学报, 2014. 36(3):696-702. (EI 期刊) . [7] 杜晓玉,孙力娟,等面向水环境监测的迭代定位算法[J],南京邮电大学学报(自然科学版), 2013.33(4):46-51. [8] 郭启程,杜晓玉*,张延宇,等.基于改进鲸鱼算法的无人机三维路径规划[J].计算机
--	---

	科学,2021,48(12):304-311. [9] 杜晓玉,刘帅起,韩志杰*,等.以患者为中心基于 IPFS 和区块链的医疗信息共享方案[J].计算机应用,2024,44(10):3122-3133. [10]Du Xiaoyu*,Cheng, Cheng; Wang, Yujing; Han, Zhijie Research on Network Attack Traffic Detection HybridAlgorithm Based on UMAP-RF[J], Algorithms,2022.9 3. 以第一发明人授权专利 [1] 基于三维定向移动的水下无线传感器网络覆盖方法（ZL201410018957.9）2015, [2] 基于极坐标的无线传感器网络覆盖方法（ZL201410166538.X），2017。 [3] 一种基于容错哈密顿圈的数据中心网络故障诊断方法（ZL202110291165.9），2022 [4] 城市环境下基于改进鲸鱼算法的无人机三维路径规划方法（ZL202011155667.0），2021 [5] 一种基于改进黑翅鸢优化算法的车联网计算卸载和资源分配方法,(ZL202510084406.0) 4. 专著 杜晓玉，面向水环境监测的传感网覆盖算法研究，河南大学出版社,2020.7
--	---

一、主要研究内容及研究价值

2024 年 9 月 9 日，在国家网络安全宣传周主论坛上，全国网络安全标准化技术委员会发布了《人工智能安全治理框架》1.0 版。该框架指出：“鼓励人工智能创新发展为第一要务，以有效防范和化解人工智能安全风险为出发点和落脚点，提出了包容审慎、确保安全，风险导向、敏捷治理，技管结合、协同应对，开放合作、共治共享等人工智能安全治理原则。”




图 1 2024 年生成式人工智能服务备案情况

这一框架为我国人工智能技术的安全发展提供了明确的方向。近年来，人工智能技术在各领域呈现出快速发展的态势。如图 1 所示，2024 年生成式人工智能服务备案数量从 2023 年 12 月的 64 款激增至 2024 年 12 月的 302 款，增长幅度高达四倍，充分反映出人工智能应

用的爆发式增长。

在此背景下，网络安全已成为人工智能的重要应用领域之一。其中，基于人工智能技术的网络入侵检测系统（NIDS, Network Intrusion Detection Systems）已成为提升网络安全防护能力的关键技术，这类系统通过深度学习、数据挖掘等人工智能技术，实时分析大量网络流量并识别异常行为，从而显著提高对恶意流量检测的精确度和响应速度。与传统基于规则的恶意流量检测方法相比，人工智能驱动的 NIDS 能够识别未知攻击模式，并有效应对高度隐蔽的网络威胁。

1. 研究内容

本课题旨在通过多维度的研究，系统分析与优化网络流量增强和替代模型训练技术，从而提升基于迁移的黑盒攻击对网络入侵检测系统对抗脆弱性的发现能力。针对（1）数据增强方法在高维流量特征中的局限性、（2）对抗攻击在异构模型之间的迁移性差异、（3）传统替代模型训练策略的不足，三种原因导致的基于迁移的黑盒对抗攻击性能不佳，以网络流量数据、深度神经网络模型及替代模型的训练策略为分析对象，以提高基于迁移的黑盒对抗攻击检测入侵检测模型对抗脆弱性的能力为目标，采用多维数据增强、对抗样本迁移性分析和替代模型蒸馏训练技术，构建了用于评估入侵检测系统对抗鲁棒性的标准化框架。系统将量化目标入侵检测模型在不同对抗攻击方法下的鲁棒性表现，并为实际部署前的系统安全性评估提供理论依据。具体内容如下。




图 2 网络入侵检测中基于迁移学习的对抗攻击研究内容分类框架

（1）异构深度神经网络架构的对抗迁移性机理研究。分析当前主流的多种适用于网络入侵检测系统的人工智能模型的特点，分别将其训练为替代模型和目标模型。同时，将研究内容一中的白盒对抗攻击算法施加于训练好的替代模型上，进而生成对抗样本。设计出通用化对抗鲁棒性评估框架，能够给出对人工智能模型对抗鲁棒性的量化评价指标，实现针对异构模

型间对抗迁移特性的有效评估。具体包括：

- **异构替代模型与目标模型结构研究。**首先，根据不同人工智能模型在网络入侵检测任务中的适用性，分析其内部结构及数据处理流程。然后训练和评估这些模型，通过对模型的准确率、召回率、F1 值及鲁棒性表现的综合评定，选取在检测精度与稳定性方面表现较优的模型作为替代模型或目标模型。
- **基于替代模型的多策略白盒对抗攻击方案。**鉴于数据类型为网络流量，将对多种白盒攻击算法进行参数化调整，例如优化最大扰动幅度等，以更好地适应网络流量的特性。随后，在替代模型上施加多种白盒对抗攻击策略，收集生成的对抗样本并用于后来对目标模型的攻击。
- **跨模型对抗样本迁移性评估机制研究。**首先，利用在替代模型上生成的对抗样本对目标模型进行攻击。针对对抗样本的迁移性，设计标准化的评估体系，通过跨模型对比实验，量化对抗样本在不同网络架构间的迁移成功率。

表 1 跨模型对抗样本迁移性评估指标体系

评估指标	核心定义	评估意义
迁移成功率	对抗样本使目标模型决策偏移的概率	衡量攻击的核心效能，是基础指标
扰动泛化度	对抗样本在多类目标模型中的有效比例	评估攻击的场景适应性，支撑泛化性判断
结构鲁棒性	迁移成功率随模型结构差异的变化幅度	刻画抗异构干扰能力，保障评估全面性

(2) **面向对抗鲁棒性评估的黑盒迁移攻击机制研究：**由于在真实场景中无法获取目标入侵检测系统的完整训练数据，采用数据增强和替代模型训练技术构建高质量的替代模型。在替代模型上生成的对抗样本用于攻击目标入侵检测系统，进而量化其在不同对抗攻击方法下的鲁棒性，最终评估其在正式部署前的对抗鲁棒性与防御性能。具体包括：

- **替代模型的构建与性能优化：**在受限的真实流量条件下，通过数据增强技术构建高质量的多维数据集。具体来说，替代模型通过有效利用目标模型输出的信息，从而学习并获取目标模型的决策模式。初步训练完成后，借助对抗样本的扰动引导，替代模型的决策边界将在高维特征空间中得到精细调整，以确保模型能够更好地应对各种对抗攻击场景。最终，替代模型将逐步逼近目标模型的决策边界，增强其在复杂攻击环境中的适应

性和鲁棒性。

- **迁移攻击与鲁棒性评估：**选取不同的替代模型和目标入侵检测系统结构，并实施一套标准化的迁移攻击与鲁棒性评估流程。通过该流程，量化模型在不同攻击强度下的对抗表现，包括攻击成功率、迁移成功率、模型性能下降等关键指标，以全面评估模型在对抗环境中的鲁棒性和适应性。

2. 研究价值

全国网络安全标准化技术委员会发布的《人工智能安全治理框架》在“3.1.1 模型算法安全风险“中的”（f）对抗攻击风险“指出：“攻击者可通过构造精心设计的对抗样本，隐蔽地误导、干扰甚至操控人工智能模型，从而引发错误输出，严重时可能导致系统瘫痪。”这一表述表明，国家层面已对人工智能模型可能面临的对抗攻击风险予以高度关注。事实上，由于人工智能模型普遍具有“黑盒”特性，缺乏透明度与可解释性，难以及时发现其潜在对抗脆弱性。在国际范围内，近年也不断出现对抗攻击案例，进一步凸显了对抗攻击的现实威胁。例如，2023年10月，卡内基梅隆大学研究团队提出了名为 LLM Attacks 的攻击算法，将其应用于主流大语言模型（如 ChatGPT、Bard 等）的测试。结果表明，这些模型在面对对抗性输入时频繁被攻破，攻击成功率高达 84%（GPT-3.5）、66%（GPT-4）和 66%（PaLM-2）。此外，2023年11月，OpenAI 安全系统负责人发布长文，梳理了大型语言模型在实际使用中遭遇的多种对抗攻击类型，包括基于 token 操作的攻击和基于梯度的攻击。这些事件表明，人工智能模型已成为攻击者的重点目标，其对抗脆弱性不仅是学术界的研究难题，也已成为产业界和政府高度关注的现实问题。因此，如何提升模型的对抗鲁棒性，已成为人工智能安全治理亟待解决的核心议题。




图3 我国移动互联网接入流量增长情况（亿 GB）

在众多人工智能应用场景中，网络入侵检测系统（NIDS）因直接关系到网络空间安全，其对抗鲁棒性问题尤为关键。面对复杂多变的攻击环境，如果在系统部署前缺乏对抗攻击测试，模型一旦暴露于实际应用中，极易被精心设计的对抗样本误导，从而造成严重的安全隐

患。为此，部署前开展系统性的对抗攻击评估，已成为保障基于人工智能的 NIDS 安全性和提升鲁棒性的必要环节。基于这一背景，课题探索面向超密集网络中多维攻击数据的对抗攻击方案，在 NIDS 正式上线前通过模拟不同强度的攻击场景，有效揭示其在真实环境中可能遭遇的对抗攻击，以及对面临未知攻击时进行 AI 模型的安全评估。这不仅为模型优化和防御机制设计提供直接依据，也有助于提升系统应对未知网络攻击的能力，从而确保其在实际网络环境中的稳定运行。

二、实验室及指导教师的条件保障（含已具备的实验条件、研究基础、实验技能等）

项目申请人杜晓玉教授是河南大学信息安全系系主任，同时为河南省大数据分析处理重点实验室中数据安全子团队的负责人。本项目核心成员均为信息安全系的科研骨干，分别在人工智能、网络入侵检测、协作通信、网络空间安全、密码学等领域具备较丰富的教学经验和科研积累。本项目依托实验室具备实施“网络入侵检测中基于黑盒迁移的 AI 模型对抗攻击研究”建设所需的软硬件资源，并且具备开展课题的实验环境。

申请人及团队成员所在的实验室已经在面向入侵检测的黑盒对抗攻击迁移性研究取得了阶段性成果，为本案例库建设工作提供了强有力的技术保障。

团队建设有相关实验室 5 个，虚拟仿真实验室（如换脸、模拟语音、网络态势感知）、网络攻击演示实验室、车联网安全实验室、网络靶场实验室和红蓝对抗实验室。项目成员在此领域有深厚的研究基础，共申报各级各类项目 10 余项，发表论文 20 余篇，指导学生大学生创新创业项目 20 余项，其中获国家级 5 项，信息安全领域知名赛会奖励 2 项，主持人为政府机关的网络信息安全专家智库成员，为政府信息安全领域的决策支持提供咨询服务，对信息安全问题有敏锐的判断。

三、项目实施方案及进度安排（按月份列出）

在现有人工智能安全与网络入侵检测研究工作的基础上，系统开展 NIDS 对抗脆弱性研究，构建标准化的对抗鲁棒性评估框架。具体计划与进度安排如下：

1) 2025.11-2026.1，完成研究环境与实验数据准备，搭建并训练多种主流的异构深度学习模型作为基线 NIDS，确立其基准性能，并复现主流白盒对抗攻击算法。

2) 2026.2-2026.5，重点研究异构模型间的对抗样本迁移性规律，并在黑盒设定下，开发基于数据增强与模型蒸馏的高质量替代模型训练技术。

3) 2026.6-2026.8，将前期技术成果集成为一套标准化的 NIDS 对抗鲁棒性评估框架，并进行系统性的实验验证与效果评估。

4) 2026.9-2026.10，进一步修改、优化现存问题，全面总结研究成果，撰写研究报告与学术论文，完成项目结题评审。

四、项目经费预算及用途

序号	经费科目	经费预算（元）	预算依据
1	论文发表及相关文献检索	6000	1 篇论文×0.6 万元/篇
2	软件服务和云服务购买	10000	云开发平台服务费和开发软件服务费
3	专利申请	4000	专利申请费用约为 4000 元
4			
5			
6			
合 计（元）		20000	

五、预期成果（包括成果形式、数量、效益及学生实践创新能力提升等）

人工智能安全治理与对抗鲁棒性研究有着重要的理论与现实意义，预期成果主要包括：

1) 研发一套“NIDS 对抗鲁棒性标准化评估框架”原型软件，可对主流 AI 入侵检测模型进行自动化安全测评并生成量化报告。

2) 基于在替代模型训练、数据增强或评估方法上成果，将申请相关技术发明专利。

3) 设计一套针对网络流量特征的对抗攻击与防御算法方案，提升 AI 模型在真实网络环境中的安全性与可靠性。

4) 发表 1 篇人工智能安全或网络安全领域的高水平学术论文，提交完整的研究总结报告 1 份。

六、依托实验室意见

同意申报



实验室主任签字: _____

2015年10月29日

七、评审专家组意见

组长签字: _____ 年 月 日

八、学校意见

领导签字: _____ 年 月 日 盖章: