

单位代码	10475
学 号	104753210919
分 类 号	TP393

河南大學

硕士学位论文

面向入侵检测的黑盒对抗攻击迁移性研究

学 科 、 专 业 ： 软件工程
研 究 方 向 ： 网络安全
申请学位类别 ： 工学硕士
申 请 人 ： 林绿洲
指 导 教 师 ： 杜晓玉 教授

二〇二四 年 六 月

A Research of Black-box Adversarial Traffic for Intrusion Detection

A Dissertation Submitted to
the Graduate School of Henan University
in Partial Fulfillment of the Requirements
for the Degree of
Master of Engineering Science

By

Lin Lvzhou

Supervisor: Prof. Du Xiaoyu

June, 2024

摘要

入侵检测是维护网络安全的一种重要手段，它们可以通过检测流量的行为判断流量是否合法。基于异常的入侵检测方案发展迅速，原因是借鉴于目前机器学习和深度学习的方案，它们有着强大的推理能力。然而有关于机器学习和深度学习有着固有的缺陷，对抗攻击就是其中的一类，它们可以通过产生微小的变化让分类器分类能力显著地下降。

当前有关对抗攻击在入侵检测领域的研究相对薄弱，大多研究专注于白盒对抗攻击方式，而入侵检测通常是黑盒场景。本文使用基于对抗攻击迁移性原理的方案，对入侵检测系统部署黑盒对抗攻击，主要工作如下：

（1）针对现有网络流量检测能力不足的问题，提出了基于 Tabnet 网络作为入侵检测分类器，研究了该模型在多分类任务下的流量检测能力，并与传统的基于机器学习的分类器进行了对比，进一步提高了恶意流量行为的检测，将其作为黑盒模型，开展后续工作。

（2）针对传统增强方案效果不适用的问题，结合流量数据的特性，设计并实施了基于 mixup 数据增强方案来辅助代理模型的生成，使用定理及其证明指出 mixup 方案对于边界值聚集现象不会出现越界，通过实验说明基于 mixup 数据增强方案的代理模型训练在时间和模型评价指标上都有良好表现。

（3）针对传统的基于迁移性的黑盒对抗攻击框架对流量数据的不适用，设计了黑盒对抗攻击框架 MSM，进一步在公开流量数据集上使用了 Tabnet、极致梯度提升以及梯度提升决策树作为黑盒入侵检测模型，使用白盒对抗攻击产生对抗流量，最后通过 MSM 方案将对抗流量迁移到黑盒入侵检测模型后评估它们表现。

（4）针对现有白盒对抗攻击在入侵检测领域中较少，通过白盒对抗攻击生成对抗流量，通过 t-SNE 方案可视化，并进一步分析了它们的保真度。

关键词：网络安全，入侵检测，机器学习，对抗攻击，代理模型

ABSTRACT

Intrusion detection is a crucial tool for ensuring network security. It is employed to ascertain the legitimacy of network traffic by analyzing its behavior. The rapid evolution of anomaly-based intrusion detection systems is attributed to their potent inferential capabilities, leveraging contemporary machine learning and deep learning techniques. However, machine learning and deep learning approaches have intrinsic vulnerabilities. Adversarial attacks are a notable example of such weaknesses, capable of inducing significant degradation in a classifier's ability to accurately categorize traffic with minor alterations.

Research on adversarial attacks in the field of intrusion detection is currently relatively weak, with most studies focusing on white-box adversarial attack methods, while intrusion detection typically occurs in a black-box scenario. This thesis proposes a solution based on the transferability principle of adversarial attacks to deploy black-box adversarial attacks on intrusion detection systems. The main contributions are as follows:

(1) To address the issue of insufficient capacity in existing network traffic detection, this thesis propose the Tabnet DNN as an intrusion detection classifier. this thesis investigate the traffic detection ability of the model under a multi-classification task and compare it with traditional machine learning-based classifiers. This approach enhances the detection of malicious traffic behaviors and serves as a foundation for subsequent work, leveraging the black-box model's capabilities.

(2) To tackle the issue of traditional enhancement schemes' ineffectiveness, a mixup data augmentation scheme was designed and implemented, specifically tailored to the characteristics of traffic data. This scheme aimed to assist in generating surrogate models. Using a theorem and its proof, it is demonstrated that the mixup scheme does not lead to out-of-bound occurrences for the phenomenon of boundary value aggregation. Experimental results illustrated that training surrogate models using the mixup data augmentation scheme exhibited excellent performance in terms of both time and model evaluation metrics.

(3) As a solution to the limitation of traditional transfer-based black-box adversarial attack frameworks on traffic data, the MSM framework is designed. This framework further utilizes Tabnet, Extreme Gradient Boosting, and Gradient Boosting Decision Tree models as black-box intrusion detection models on a public traffic dataset. Adversarial traffic is generated using a white-box adversarial attack. Finally, the performance of the adversarial traffic is evaluated after transferring it to the black-box intrusion detection models through the MSM scheme.

(4) Addressing the scarcity of white-box adversarial attacks in the field of intrusion detection, we generate adversarial traffic using a white-box approach. We visualize this traffic using the t-SNE method and further analyze its fidelity.

KEY WORDS: Network Security, Intrusion Detection, Machine Learning, Adversarial Attacks, Surrogate Model

目 录

第 1 章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 发展历史.....	2
1.2.2 研究现状.....	4
1.3 研究工作与创新.....	5
1.4 文章组织结构.....	5
第 2 章 相关理论及技术介绍	7
2.1 网络入侵检测技术.....	7
2.1.1 网络入侵检测基本概念.....	7
2.1.2 入侵检测技术分类.....	7
2.2 应用于入侵检测的模型学习	8
2.2.1 机器学习方案.....	8
2.2.2 深度学习方案.....	10
2.3 对抗攻击方案.....	11
2.4 网络流量数据集.....	13
2.4.1 NSL-KDD 数据集	13
2.4.2 UNSW-NB15 数据集	14
2.5 实验相关评价指标.....	15
2.6 本章小结.....	16
第 3 章 基于 MSM 的黑盒对抗攻击威胁框架	17
3.1 引言.....	17
3.2 MSM 网络流量黑盒对抗攻击威胁模型	17
3.3 基于 mixup 的流量数据生成方案	19
3.4 基于 Tabnet 的黑盒入侵检测模型的构建.....	23
3.4.1 整体模型结构.....	23
3.4.2 转换器模块.....	24
3.4.3 特征转换模块.....	25
3.4.4 设计流程.....	26
3.5 实验设计与分析.....	27
3.5.1 数据预处理.....	27
3.5.2 Tabnet 超参数设置以及不均衡性矫正	28
3.5.3 Tabnet 入侵检测模型对比	30
3.5.4 MSM 下代理模型实施	32

3.5.5 mixup 数据增强对比方案	33
3.6 本章小结	35
第 4 章 对抗流量及其 MSM 下的迁移性	37
4.1 引言	37
4.2 对抗流量实施方案	37
4.2.1 FGM 对抗流量实施方案	37
4.2.2 PGD 对抗流量实施方案	38
4.2.3 SLIDE 对抗流量实施方案	39
4.2.4 C&W 对抗流量实施方案	39
4.3 基于 t-SNE 的对抗流量可视化	40
4.4 实验分析	42
4.4.1 对抗流量可视化	42
4.4.2 不同流量类别的对抗攻击敏感度	44
4.4.3 迭代白盒对抗攻击在流量数据中的表现	48
4.4.4 白盒攻击迁移到黑盒模型上的表现	49
4.5 本章小结	52
第 5 章 总结与展望	53
5.1 总结	53
5.2 未来展望	54
参考文献	55

第 1 章 绪论

1.1 研究背景与意义

随着 5G、大数据、人工智能等新技术的广泛应用，网络安全面临的威胁日益增加。日益严峻的网络风险引发了政府部门、企业和个人的高度关注，全球各国均开始紧急出台和更新数据保护法规以应对挑战。2017 年 6 月，《网络安全法》正式实施，2019 年 5 月，中国发布了等级保护 2.0 国家标准，其中加入了对个人信息保护和云计算等方面的更多要求。根据中国互联网络信息中心 (China Internet Network Information Center, CNNIC) 发布的第 52 次《中国互联网络发展状况统计报告》。截至 2023 年 6 月，我国网民规模达 10.79 亿人，较 2022 年 12 月增长 1109 万人，互联网普及率达 76.4%^[1]。此外，我国移动电话基站总数达 1129 万个，其中累计建成开通 5G 基站 293.7 万个，占移动基站总数的 26%。移动互联网累计流量达 1423 亿 GB，同比增长 14.6%。由此可见，网络发展迅速，这足以证明互联网所拥有的举足轻重的地位。

时至今日，全球数字化仍以惊人的速度发展，相关投资持续增长。Web 3.0、元宇宙等已然成为时下热门议题——据估计，2023 年数字经济产值将占全球 GDP 的 60% 以上。然而，在数字经济蓬勃发展的同时，背后的网络生态系统却在发生根本性变化。原本全球化的网络架构在网络空间武器化以及各国利益冲突的共同作用下逐渐瓦解，演变为区域化乃至国家化的架构。2023 年，全球网络和系统韧性将遭遇前所未有的挑战。故而，构建网络安全维护方案非常重要。

目前，网络攻击方案多种多样，包含不同的范式和原理，网络用户们面临海量且不断变化的攻击行为。防火墙、数据加密、入侵检测系统等技术是现有主要的相关安全防护技术。

因此构建起一种普适的方案非常重要，其中入侵检测技术发展迅速，变得越来越重要^[2]，它广泛应用于军事领域^[3]、医疗领域^[4]、交通领域^[5]、物联网领域^[6]、工业控制领域^[7]。在产业界和学术界相关实践和研究非常丰富。入侵检测系统可以从检测技术上分为两类：基于签名的和基于异常的。随着机器学习和深度学习的快速发展，基于异常的入侵检测逐渐成为主流方案^[8]。

然而自从 2013 年开始，SZEGEDY 等人揭示了深度神经网络脆弱性^[9]，到 2014 年

GOODFELLOW 等人^[10]提出了对抗攻击的概念, 后续越来越多的人发现深度神经网络可能并没有人们想的那么健壮, 其鲁棒性需要有所考虑。基于机器学习的入侵检测系统也需要考虑对抗攻击的风险^[11]。对抗攻击这类攻击可以对原始样本进行微小的变化进而导致模型输出结果显著变化^[12]。对于构建对抗攻击的意义有两点: 一是通过构建对抗攻击来评估模型的鲁棒性^[13], 二是为对抗防御方案提供可供选择的对抗攻击。

由于对于入侵检测领域的基础数据——流量数据其特征提取不可逆^[14] (3.2.1 节详细解释), 这不同于图像文本等领域可以使输入空间到特征空间可逆变换。这导致直接对于黑盒模型使用基于梯度或雅可比矩阵的方案实施起来有难度。同时考虑入侵检测系统极强的实时性特点, 需要设计更可靠的黑盒对抗攻击威胁方案。

1.2 国内外研究现状

近年来, 随着互联网 5G 的落地, 网络流量更加的复杂化、海量化。网络安全逐渐越来越重要, 进而催生入侵检测技术发展迅速, 网络空间成为第五前言^[15], 入侵检测类型许多, 其中基于异常的入侵检测使用机器学习和深度学习的方案发展迅速, 它们可以分为有监督和无监督模型。由于输入神经网络的需要, 入侵检测系统需要进行原始流量数据的变化才能进行检测。入侵检测逐渐朝着智能化方向发展, 不同方案的角度不同, 国内外相关研究人员都取得了不同的进展。然而目前发现已有的对抗攻击方法不仅适用于计算机视觉领域, 而且适用于许多其他基于机器学习系统的领域^{[16]-[18]}, 其中包括入侵检测^{[19]-[21]}。

1.2.1 发展历史

入侵检测(Intrusion Detection), 是指通过监控系统的运行状态, 发现各种攻击企图、攻击行为或攻击结果, 以确保系统资源的保密性、完整性和可用性。入侵检测软件和硬件的结合就是入侵检测系统(Intrusion Detection System,IDS)。

James P. Anderson 在其技术报告中首次提出了入侵检测的概念。他将入侵企图或威胁定义为潜在的、有预谋的、未经授权的企图, 可能涉及访问和操纵信息, 以破坏系统的可靠性和可用性。这一定义为计算机安全领域奠定了理论基础, 强调了监测和识别潜在威胁的重要性^[22]。

1990 年是入侵检测系统发展史上重要的一年, 因为这一年里入侵检测系统发展史分为了两大阵营, 加州大学戴维斯分校的 L.T.Heberlein 等人开发出了基于网络的入侵

检测系统(Network Intrusion Detection System, NIDS)^[23]；网络安全监测(Network Security Monitor, NSM)。该系统首次直接使用网络流作为审计数据源，因此无需将审计数据转换为统一格式即可监控异构主机。此后，入侵检测从数据源上可分为：基于网络的 IDS 和基于主机的 IDS (Host-based Intrusion Detection System, HIDS)^[24]。

入侵的种类越来越多，攻击的范围也逐渐扩大。许多攻击都是经过长期准备并通过在线协作实施的。面对这种复杂性，入侵检测系统内部不同功能组件之间以及不同入侵检测系统之间共享攻击信息变得至关重要。

为解决这一问题，Chen 等学者提出了一种被称为威胁情报检测框架 (Cyber Threat Intelligence Detection Framework, CIDEF) 的通用入侵检测框架模型^[25]。该模型将入侵检测系统划分为事件产生器(event generators)、事件分析器(event analyzers)、响应单元(response units)以及事件数据库(event databases)。如图 1.1 所示。




图 1-1 CIDEF 通用入侵检测框架

本文所研究的入侵检测系统特指基于异常的入侵检测中使用机器学习深度学习方案充当事件分析器的 IDS。

有关于对抗攻击发展历史，最早追溯到 2013 年 SZEGEDY[9]等人揭示神经网络脆弱性开始，并在 2014 年被 GOODFELLOW^[10]等人将这一现象称为对抗样本也称为对抗攻击。此后越来越多的研究者专注研究该领域，目前有关于对抗攻击产生的成因目前还是一个疑点。SZEGEDY 等人认为是由于分类器在学习阶段只能接收到局部子区域，一旦对抗样本超出了分类器在学习阶段所认知的区域，便会导致神经网络分类的错误。但是，GOODFELLOW 等人从其他角度论述了这个问题。他们认为这是由于深度神经网络的脆弱性导致的，特别是使用某些线性的激活函数，例如 ReLU、Maxout 等，这是由于研究者们通常在使用激活函数时，通常在线性区域让分类网络学习造成的结果。2017 年，ARPIT 等人^[26]在他们的研究中发现记忆能力强的模型更容易收到对抗样

本的影响。2018 年, GILMER^[27]等人认为数据流形的高维几何结构产生了对抗样本。但不管怎样, 该领域发展依然迅猛, 其主要目标依然是攻击分类器使其分类精度下降的这一前提下开展的。目前已有很大突破。

1.2.2 研究现状

对抗攻击是近十年内发展的, 相较于入侵检测是一个年轻的领域, 最早完整提出的一种对抗攻击方案是 FGSM(fast gradient signed method)^[10], 后续研究者们提出了 PGD(Projected Gradient Descent)^[28]、JSMA (Jacobian-based Saliency Map Attack)^[29]、DeepFool^[30]、C&W(Carlini and Wagner)^[13]等通用方案。这些方案广泛的应用于入侵检测, 例如文献[19]使用对抗攻击中 FGSM、JSMA 等白盒方案针对多层感知机、决策树、随机森林等模型下构成的集成分类器进行了攻击, 在 NSL-KDD 数据集上证明了以上构成的机器学习充当的 IDS 无法抵抗对抗攻击。文献[31]更进一步的评估了 C&W 和 DeepFool 者两种攻击对于 IDS 施加的有效性。文献[32]在 KitNet 上证明了 FGSM、JSMA 等攻击方案的有效性, 在 Mirai 数据集上评估了其有效性。文献[21]在 NSL-KDD 使用 C&W、ZOO^[33]方案针对 MLP 充当的入侵检测系统进行了对抗攻击。也有使用其他方案来生成对抗攻击, 例如文献[34]利用 WGAN^[35]对分类网络进行了对抗攻击, 通过仅保留对非功能的特征进行扰动。文献[36]基于 StarGAN 并且结合了多个损失函数, 提出了一种基于对抗性转换网络的对抗攻击方法。文献[37]面向入侵检测使用了四种对抗攻击方案, 并结合三种启发式防御策略, 以提高入侵检测在对抗攻击情况下的鲁棒性。

国内相关研究相对较少, 主要集中在白盒的情境中实施。例如, 文献[37]提出了使用频域的对抗攻击算法, 对比了 FGSM 和 JSMA 方案, 结果表明频域对抗攻击算法更加优秀。文献[39]提出了基于注意力机制的 GAN 对抗攻击模型在 KDD-CUP99 以及 UNSW-NB15 数据集上生成的对抗流量。文献[40]在 NSL-KDD 数据集上进行了 JSMA 以及 FGSM 等方案, 并评估对抗攻击的迁移性。文献[41]利用生成式对抗网络并且和基于核密度估计(KDE)的方案生成对抗流量, 并在多个数据集上评估了攻击方案。文献[42]训练了一个强化学习网络进行对抗攻击, 实验证明了当前漏洞检测模型具有被对抗攻击威胁的风险。

目前有关入侵检测的对抗攻击方案比较薄弱, 国内则更甚, 近几年多数国内研究大多讨论的是传统的分类器, 在决策流模型上评估对抗攻击的方案较少, 并且大多是

传统的白盒方案，黑盒方案所提的较少。

1.3 研究工作与创新

现有入侵检测有关网络流量的对抗攻击研究尚不够充分，国内外有关此方面研究的流量数据涉及到的对抗攻击方案多数关注于部分传统机器学习分类器，且攻击方案中白盒方案居于首要地位。在现有的白盒对抗攻击方案不足且现有研究对黑盒模型讨论有限的前提下，缺少通用的关于对抗流量的黑盒方案。本文针对上述情况提出以下创新：

1.结合现有的入侵检测模型对于网络流量的检测能力不足的问题，使用 Tabnet 作为黑盒入侵检测模型，在入侵检测的数据集上验证了该方案的有效性，为入侵检测相关研究提出了一种新的方案。

2.针对传统的数据增强方案对于训练代理模型的效果不佳问题，提出了基于 mixup 数据增强方案辅助代理模型以使其达到黑盒模型的流量检测能力，这项作为黑盒模型的对抗攻击迁移性提供了一定的研究基础。

3.设计并实施了 MSM 黑盒对抗攻击威胁方案，这是一种限制源流量获取、仅通过获取待攻击模型推理结果实施的，因此该方案具有场景适应性。进一步使用 FGM、PGD、C&W、SILDE 这四种白盒对抗攻击来产生对抗流量，通过在代理模型中实施这四种方案，并通过 MSM 方案迁移到黑盒的入侵检测模型中。

4.评估了 NSL-KDD、UNSW-NB15 这两个网络流量数据集上本文方案的效果。并结合梯度提升决策树(Gradient Boosting Decision Tree,GBDT)和极致梯度提升(eXtreme Gradient Boosting,xgboost)以及 Tabnet 分类器，以确保本文的方案在流量数据集上的广泛的可行性。

1.4 文章组织结构

本文一共分为五章，各章涉及内容如下：

第一章：绪论。本章节介绍了网络安全现状，网络安全领域有关入侵检测的研究背景及研究意义，入侵检测的发展历史和面临对抗攻击的风险，总结了目前相关研究存在的现状和不足以及针对这些不足本文所做的研究工作，文章的创新内容，同时概括了各个章节的组织结构。

第二章：相关理论及技术介绍。本章节介绍了有关入侵检测技术分类，涉及到入

侵检测技术及其常见机器学习、深度学习方案，也介绍了对抗攻击方案以及相关的对抗攻击研究，最后介绍了相关数据集和评价指标。

第三章：基于 MSM 的黑盒对抗攻击实施方案。此章节提出了基于 MSM 的黑盒对抗攻击框架，基于代理模型实施黑盒对抗攻击，并提出了一种基于 mixup 数据增强的方法来生成代理模型，相关的证明和实验说明了该方案的优越性。

第四章：对抗流量及其 MSM 下的迁移性。此章节使用对抗攻击方案 FGM、PGD、SILDE、C&W 产生对抗流量，并进一步评估了它们在 MSM 威胁框架下迁移前后的表现，此外，用 t-SNE 方案可视化了上述对抗攻击产生的对抗流量的低维表现形式。

第五章：总结与展望。对已有工作进行归纳，提出现有工作的不足，并结合有关对抗攻击产生对抗流量有关发展的设想，提出面向未来的展望。

第2章 相关理论及技术介绍

本章首先介绍了入侵检测技术的相关概念，常见的机器学习算法、概念、分类，然后介绍了对抗攻击通用的攻击方案，最后介绍了本文使用到的网络流量相关的公开数据集以及实验中算法分类性能评价指标。

2.1 网络入侵检测技术

2.1.1 网络入侵检测基本概念

网络环境越来越复杂，网络攻击类型越来越多，现如今网络攻击不断发展，逐渐发展为多种类型的网络攻击方案。例如，借助嗅探器开展的嗅探攻击，建立黑客终端的截获类攻击，拒绝服务攻击，借助傀儡主机部署的僵尸网络攻击等，网络流量成为网络安全的重要威胁方式。因此专注于网络流量监测的入侵检测应运而生。它是一种积极主动的防护手段，有效防御了针对内部和外部的网络攻击。

网络威胁情报检测框架(CIDF,Cyber Threat Intelligence Detection Framework)的体系结构文档将一个IDS分为以下四个组件：事件产生器(Event generators)、事件分析器(Event analyzers)、事件数据库(Event databases)响应单元(Response units)。其中，事件产生器是采集数据的模块，它负责从整个计算环境中获取事件，并以CIDF的GIDO格式传递给系统的其他部分，该组件是所有入侵检测系统所需的，同时也具有可重用性。

(GIDO是通用入侵检测对象，CIDF中各个组件借此进行数据交换)。事件分析器充当分析部分，接收GIDO数据，并通过误用/异常检测算法进行分析，生成新的GIDO。这个组件是应用误用/异常检测算法的地方。事件数据库是包含日志的存储部分，用于统一存放各种中间和最终数据。它可以是复杂的数据库，也可以是简单的文本文件，并支持持久化存储。响应单元不仅能够发出警报也负责对分析结果做出其他反映，比如进行进程的终止、连接重置、更改文件属性等操作。它还可以与防火墙等其他安全设备联动响应。

2.1.2 入侵检测技术分类

入侵检测有许多分类方法，下面对这些方法进行概括：

(1) 根据数据来源划分

从数据来源划分为, 入侵检测分为基于主机的入侵检测系统(HIDS)和基于网络的入侵检测系统(NIDS), HIDS 通常位于被监视系统的软件组件中, 监视主机系统的状态和操作, 检测系统事件, 例如通过浏览日志、文件系统修改以及其他活动来检测入侵^[41]。HIDS 大多数系统分为程序级 IDS 和系统级 IDS, 前者注重单个应用程序, 后者监视整个系统状态, 涉及系统日志, Windows 注册表数据等^[44]。NIDS 通过检查网络数据包检测攻击, 能够检测更广泛的网络协议, 通常需要专门的硬件。

(2) 根据检测技术划分

基于检测技术划分来看, 入侵检测系统可以分为, 基于误用的入侵检测(Misuse-based Intrusion Detection System, MIDS)^[45]和基于异常的入侵检测 (Anomaly-based Intrusion Detection System, AIDS)。

其中, 基于误用的入侵检测主要包括: 1.状态建模^[46]。2.字符串匹配^[47]。3.专家系统^[48]。

基于异常的入侵检测是通过异常行为与正常行为偏离较大时发出告警信息从而进行检测。从模型学习的角度还包括基于传统机器学习、深度学习、强化学习等方法。此类方法是本文研究的重点, 本文提出的方案主要就是针对此类的入侵检测开展的黑盒攻击方案。

2.2 应用于入侵检测的模型学习

本节所指的模型学习指的是一部分适应于机器学习和深度学习的方案, 入侵检测在这部分的研究主要集中于一些轻量型、推理时间快的模型。机器学习与深度学习这二者中的一些经典方案构成了上述基于异常的入侵检测方案的主要研究内容, 充当事件分析器组成入侵检测的核心构件, 主要包括以下部分。

2.2.1 机器学习方案

(1) 决策树

决策树(Decision Tree, DT)是一种决策流方案, 该方案在处理二维表格数据时非常常用, 它是一种树形结构, 每个叶子节点代表一个分类, 每个非叶子节点表示从根节点到该叶节点路径表示对象的值。

决策树方案计算复杂度低, 模型轻量, 构造的规则易于理解, 在入侵检测中应用

比较广泛,文献^[49]通过预处理 12 个特征使用决策树算法对网络数据进行分类。文献^[50]提出了多属性框架的决策树方案,他们通过选择核心向量,将数据分为左、右、中三个部分区域部署分类方案。

(2) 随机森林

随机森林是一种集成模型分类器,它通过构造许多分类树从而构成森林,将多个弱分类树的分类结果进行投票,从而构建一个强分类器。其中的每个分类子树一般情况下是随机且有放回的从训练集中抽取训练样本作为该树的训练集,因此每颗子树训练数据都不完全一样,进而每颗子树都有可能对于每一个样本数据给出不同的投票结果。

文献^[51]通过使用 KNN 方案剔除离群数据,然后构造一个高效数据集,进而使用提出的类别检测划分方法,最后使用随机森林模型来检测异常行为。文献^[52]使用高斯混合聚类以及随机森林分类器对聚类结果进行训练。

(3) 朴素贝叶斯

朴素贝叶斯(Naive Bayes, NB)中的朴素是假设各特征之间相互独立,通过给定训练集,以及贝叶斯分类器学习输入输出的联合概率分布,预测阶段通过输入 X 求的概率最大的 Y 。这种方法在早年有一些参考方案。

例如文献^[53]使用朴素贝叶斯的方法一用到入侵检测系统中,该文作者通过预处理的相关操作,使 KDD99 数据集得到输入特征,然后通过朴素贝叶斯分类,该方法有效检测了特洛伊木马、假消息攻击等方案。文献^[54]提出了朴素贝叶斯与粒子群算法结合的方案,作者使用了粒子群算法加权到入侵检测模型上。

(4) 贝叶斯网络

贝叶斯网络(BN)是用于模拟人类推理过程中因果关系的模型。该模型采用有向无环图(DAG)作为其网络拓扑结构,图中的每个节点代表不同的含义,如变量、隐变量或未知参数等。当两个节点之间存在因果关联时,即一个节点作为因,另一个节点作为果,它们之间会形成一个条件概率值,并在图中进行直观展示。

由于其具有较强的推理能力,该方案广泛应用于入侵检测领域。文献^[55]使用提出了贝叶斯网络分类器在使用马尔可夫链蒙特卡罗采样技术获得的几个不同节点阶上的贝叶斯模型平均方案。文献^[56]使构建了一个用于网络数据包跟踪的分层 CTBN 模型,并使用 Rao-Blackellized 粒子滤波来学习参数,该方案于 DARPA 1998 BSM 数据集上进

行展示。

2.2.2 深度学习方案

(1) 自动编码器

自动编码器(AE)主要由输入层、编码层和解码层组成。与之相比,深度自动编码器(DAE)在结构上增加了隐藏层的深度,从而使其能够学习到更高层次的特征。作为一种无监督学习算法,AE 因其输入与输出之间的对称性,也能用于回归任务。在实际应用中,一种有效的方法是通过正常数据训练 AE,并利用损失函数来评估新传入的数据流量。

AE 相关方案是在入侵检测中非常常见,文献^[57]构建了一种名为 DAGMM 的异常检测网络,作者使用 DAE 构建压缩网络,并将所获得的 DAE 输入层到输出层残差作为拼接向量接入到估计网络中,进行分类任务,该文的实验数据集中包含用于网络流量的 KDD99 数据集。文献^[58]使用 AE 进行数据降维用来解决神经网络瓶颈特征提取,并在 NSL-KDD 数据集上进行了实验。

(2) Kitsune

Kitsune^[59]是一种无监督学习方法,它是一种轻量型的入侵检测模型,其具有动态维护和从网络流量中提取特征的框架,并通过其中的重要构件 Kitnet 进行后续工作。




图 2-1 Kitsune 框架

图 2-1 是 Kitsune 的基本框架,最左侧的包获取(Packet Capturer)通过 Wireshark 等包获取 API 工具进行流量数据的捕获,Packet Parser 为输入特征做准备。再通过特征提取以及转化特征图输入后续的 Kitnet 中进行分类工作,其中 Kitnet 中输入为网络数据包的特征分组,每一组特征反映每一类特性,对于每一类特性构建单独的 AE。再将每一个 AE 输出结果集成作为一个新输入,在训练最终的 AE。

(3) 长短期记忆网络

长短期记忆网络(Long Short Term Memory,LSTM)网络流量具有顺序性,故而以此

为基于 LSTM 的入侵检测方案有了发挥的情况^[60]，一种有关 LSTM 的入侵检测方案是通过输入流量数据的序列，即输入数据集中相邻的流量，输入流序列使用一个标签，从而捕获相邻流量的时间关系。

文献^[61]提出了一种双向 LSTM 网络来讲测物联网中的网络攻击，并在 UNSWNB-15 上检测了他们的方案。文献^[62]利用 AE 来降维和特征提取来重建输入数据，使用 LSTM 进行后续工作。文献^[63]使用卷积 LSTM 网络充当误用检测模块，提出了与 Spark ML 混合的入侵检测方案。

2.3 对抗攻击方案

从攻击者掌握模型的知识层面来看，对抗攻击方案可以分为白盒攻击和黑盒攻击。对抗攻击黑盒与白盒的区别是源于所获得的攻击者的知识，比如有关于被攻击模型的神经网络类型、结构、损失函数以及训练集有关信息。

深度学习中的对抗攻击特指一类经过一些针对原始样本细微的修改从而让特定分类器误判的特殊攻击形式。这种攻击最早发源于计算机视觉领域，后续人们在无人车、语音识别、入侵检测领域等领域也应用起此类攻击策略。通常情况下，对抗攻击有两个基本目标：(1)尽可能小的改动程度。(2)尽可能有效的攻击成功率。这两个目标可以表示为公式(2-1)以及公式(2-2)：

$$\text{minimize } D(x, x + \epsilon) \quad (2-1)$$

$$\text{such that } C(x + \epsilon) = t^* \neq t \quad (2-2)$$

其中， $D(x, x + \epsilon)$ 表示 x 和 $x + \epsilon$ 之间的距离度量函数， x 表示原始样本数据， ϵ 表示扰动， $x + \epsilon$ 表示添加扰动后的样本数据， C 表示分类器， t 表示样本原始的标签， t^* 表示添加扰动后的分类结果，对抗攻击实施成功的结果是让分类器 C 对添加扰动后的样本 $x + \epsilon$ 对应的分类结果 $t^* \neq t$ 。

(1) 白盒对抗攻击

白盒对抗攻击是指攻击者对于待攻击的模型以及供模型训练的数据掌握的能力非常强，整个模型训练过程中各个部分是可见的，因此称为白盒攻击。

FGSM^[10]：计算成本较低且生成速度较快，但其在攻击能力方面稍显不足。因此，它更适用于那些对攻击效率有较高需求的应用场景。其工作原理是通过模型损失函数梯度，选择一个扰动 ϵ 来进行一次攻击。其中 ϵ 规定攻击的幅度， sign 表示符号函数， $\nabla_x L(x, y)$ 表示对输入 x 的一阶偏导数。FGSM 原理由公式(2-3)所示：

$$x' = x + \varepsilon \times \text{sign}(\nabla_x L(x, y)) \quad (2-3)$$

PGD^[28]: 该种对抗攻击是通过 FGSM 改良的, 可以看作是 FGSM 迭代而来, 相比于对抗攻击 BIM(Basic Iterative Method), 加入了随机化初始造成的过程。PGD 原理由公式(2-4)所示。 $\text{Clip}\{\}$ 表示迭代, 对于每次迭代后扰动 x'_{i+1} , 是通过 x'_i 以及本次根据对损失函数求导得到的结果。该表达式中的 ε 、 $\nabla_x L(x, y)$ 同 FGSM 中的表达式。

$$x'_{i+1} = \text{Clip}\{x'_i + \varepsilon \times \text{sign}(\nabla_x L(x'_i, y))\} \quad (2-4)$$

JSMA^[29](Jacobian-based Saliency Map Attack): 寻找对特定输出影响最大的输入特征对。干扰方式为正向和反向的扰动, 不断重复有目标的攻击方案, 直到指定的输出类为概率最大的类。

DeepFool^[30]: 此种对抗攻击方案类似于 SVM 的超平面分类, 主要的设计方式是通过找到改变分类器决策的最小扰动在 F 上正交投影。并给予分类器迭代线性化生成让分类器标签改变的最小扰动。

C&W^[13]: 该方案通过优化设计了一系列的目标函数, 在选择不同的目标函数和盒约束方案下进行攻击, 该方案是目前最先进的白盒攻击方案之一。

(2) 黑盒对抗攻击

黑盒对抗攻击, 是指对分类模型以及内部详细信息不可知, 或者提供训练黑盒分类器的数据仅有少量掌握, 黑盒对抗攻击方案可以分为三种方式: 基于迁移的方式, 基于分数的方式, 基于决策的方式。

迁移性对抗攻击主要依赖于对抗样本在不同模型间的可迁移性。具体来说, 通过白盒模型生成的对抗样本, 可以成功转移到黑盒模型中实施攻击。这种迁移性指的是在某一模型上生成的对抗样本能够有效攻击另一个模型, 从而使得迁移性对抗攻击成为一种有效的黑盒攻击策略。例如文献^[64]^[64]通过对抗攻击迁移性, 使用雅可比矩阵的数据增强方案创建合成数据集迁移对抗攻击。文献^[65]使用存储层采样拓展了对抗攻击代理模型的方案, 并提高了代理模型训练过程效率。

基于分数的对抗攻击方法通过利用目标模型对输入样本输出的各个类别概率分数来估算损失函数的梯度, 进而生成对抗样本。这种方法无需深入了解目标模型的内部结构, 也无需训练额外的代理模型。文献^[66]结合了查询黑盒模型接口以及使用代理模型转移的方式, 提出了随机无梯度方案。文献^[67]在预训练的代理白盒模型中的初步生成对抗攻击, 然后利用黑盒对抗攻击方案, 提高了黑盒攻击的正确率, 减少了查询次

数。

基于决策的对抗攻击主要特点是仅依赖于目标模型最终输出的标签类别来生成对抗样本。基于决策的黑盒攻击无需训练额外的代理模型，也无需了解每个输入样本属于不同类别的概率分数。然而，为了达到最佳的攻击效果，这种攻击方式通常需要多次查询目标模型。这种攻击方式也被称为硬标签攻击。文献^[68]提出边界攻击，这是通过沿着对抗区域和非对抗区域执行随机游走，通过一个大的让分类器误判结果的扰动开始，依次减小这个扰动，并能让分类器分类误判。文献^[69]通过零阶梯度估计以及随机无梯度，提出了能够保证收敛的决策对抗攻击方案。

2.4 网络流量数据集

数据集构建应当尽可能多的特征作为主要的收集目标，这样可以提供尽可能多的分析。不仅如此，也应当考虑数据可用性和存储成本以及采集成本等问题。

对于入侵检测领域的数据集构建过程，可以按照入侵检测系统类型划分，分为网络入侵检测以及主机入侵检测。对于前者采用嗅探和数据包截获的方法获得流量数据。对于后者，采用操作系统或者应用系统的日志来获取主机数据。故而，网络连接相关，网络请求相关，数据包信息和日志信息都是评估入侵检测的常见数据来源。本文使用了 NSL-KDD 数据集以及 UNSW-NB15 这两个数据集。

2.4.1 NSL-KDD 数据集

NSL-KDD 数据集是 KDDcup99 数据集的进阶版。由于 KDDcup99 数据集的固有问题，例如 KDDcup99 数据集中的一个重要缺陷是包含大量的冗余数据，大约 78% 和 75% 的数据分别在训练集和测试集中重复，后续的研究者们提出了更为准确的 NSL-KDD 数据集来研究入侵检测的相关问题。它不含训练集中的冗余数据，因此分类器不会表现出对部分类过多的关注（冗余数据相当于重复训练）。

NSL-KDD 数据集从提供的特征来看，可以分为四类：内在特征，内容特征，基于时间的特征和基于主机的特征。其中，内在特征是数据包头获得的信息，对应特征 1-9。例如，表示协议类型的 'Protocol Type' 特征；表示数据包涉及的服务 'Service' 特征；标志位 'Flag' 特征等。

内容特征是指原始数据包中包含的有效载荷，对应特征 10-22。例如，内容中 "热门" 指标的数量，如：进入系统目录、创建程序和执行程序，对应 'Hot' 特征；登录失败

次数对应'Num Failed Logins'特征。

基于时间的功能在两秒窗口内对流量输入进行分析，对应特征 23-31。例如，过去两秒内连接到与当前连接相同的目标主机的连接数，对应'Count'特征；过去两秒内与当前连接相同的服务（端口号）的连接数，对应'Srv Count'特征；

基于主机的功能指的是连接进行的分析，旨在访问跨度超过两秒的窗口时间跨度攻击，对应特征 32-41。例如，具有相同目标主机 IP 地址的连接数，对应特征'Dst Host Count'；端口号相同的连接数，对应特征'Dst Host Srv Count'。

NSL-KDD 还统计了 39 种流量类型，并进一步分为 5 个大类。如表 2-1 所示。

表 2-1 NSL-KDD 中流量分类

类型	含义	包含的流量种类
Normal	表示正常流量数据。	normal
Dos	表示恶意流量中的拒绝服务攻击 (Denial of Service)，目的是让计算机无法正常服务。	Processtable, neptune, land, pod, smurf, teardrop, mailbomb, udpstorm, apache2, worm, back
u2r	表示恶意流量中的，目的是非法获取权限。	buffer_overflow, loadmodule, perl, rootkit, sqlattack, xterm, ps
R2L	表示恶意流量中(Remote to Local)，目的是远程获取本地访问权限。	xlock, ftp_write, imap, spy, multihop, warezclient, named, phf, warezmaster, xsnoop, snmpgetattack, httptunnel, snmpguess, sendmail, guess_passwd
Probe attacks	表示恶意流量中的通过系统漏洞获取访问权限。	satan, ipsweep, nmap, portsweep, saint, mscan

2.4.2 UNSW-NB15 数据集

澳大利亚网络安全中心(ACCS, Australian Centre for Cyber Security)在网络靶场实验室模拟了异常流量，所使用的是 IXIA PerfectStorm 工具，UNSW-NB15 数据集由模拟期间生成的报告设计的，训练集和测试集共计 257673 条流量记录。

数据集共计 49 个特征，可以分为基于流的特征、基础特征、内容特征、时间特征。流特征包括源地址源'srcip'，端口号'sport'，目的地址'dstip'，目的端口号'dsport'等。

基础特征包括流量记录总时长'dur'，源字节'sbytes'，目的字节'dbytes'，来源地到目的地的生存时间'sttl'等。内容特征包括源 TCP 序列号'stcbp'，目的地 TCP 序列号'dtcbp'

'，源传输的流量包大小的平均值'smeansz'，http 请求/响应事务的连接深度'trans_depth'等。时间特征包括记录开始时间'stime'，记录结束时间'ltime'，源数据包间到达时间'sint_pkt'，TCP 的 SYN 和 SYN_ACK 数据包之间的时间间隔'synack'等。数据集共包含了 9 种攻击和 1 种正常类型，共计 10 种流量数据。它们分别是：Normal(正常类)、Reconnaissance(侦查类，通过扫描整个网络侦查目标攻击对象来获取信息)、Backdoor(后门类，绕过系统的安全措施非法获取目标文件和数据)、Worms(蠕虫类，一种具有高传染性的计算机病毒)、Analysis(分析类，未授权的扫描、恶意邮件和非法渗透攻击的集合)、Shellcode(外壳代码类，利用软件漏洞执行一段代码进行攻击)、Generic(通用类，针对所有块密码和加密系统的攻击技术)、Fuzzers(模糊类，向目标程序发送随机生成的数据对其进行破坏)、Dos(拒绝服务类，造成网络资源对用户不可用的一种拒绝服务攻击)、Exploits(攻击类，利用目标系统或程序中的漏洞来控制系统)。

2.5 实验相关评价指标

本文用于评估模型的评价指标包括准确(Accuracy)、准确率(Precision)、召回率(Recall)，和(F1_score)。由于本文涉及的入侵检测流量分类都是多分类情况，故准确率、召回率、F1_score 都采用宏平均(Macro-average)。

对于流量数据类别为*i*的流量，TP(True Positive)表示分类器将流量正确的预测为类别*i*，TN 表示流量数据类别为*i*的流量被分类为其它类型的流量，FP 表示类别非*i*的流量被错误的预测为类别*i*，FN 表示非*i*的流量被分类为非*i*类型的流量。

准确率的计算公式如公式(2-5)所示：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2-5)$$

宏精确率(Macro-Precision)的计算公式如公式(2-6)所示：

$$Macro - Precision = \frac{1}{k} \sum_{i=1}^k \frac{TP_i}{TP_i + FP_i} \quad (2-6)$$

宏召回率(Macro-Recall)的计算公式如公式(2-7)所示：

$$Macro - Recall = \frac{1}{k} \sum_{i=1}^k \frac{TP_i}{TP_i + FN_i} \quad (2-7)$$

宏 F1 分数(Macro-F1_Score)的计算公式如公式(2-8)所示：

$$Marco - F1_Score = \frac{1}{k} \sum_{i=1}^k \frac{2 \times Marco - Precision \times Marco - Recall}{Marco - precision + Marco - Recall} \quad (2-8)$$

评估对抗攻击的评价指标攻击成功率(ASR, Attack success rate), L2 距离保真度。

攻击成功率表示实施对抗攻击成功改变样本数据标签的数量, 对于对抗攻击的攻击成功率定义为公式(2-9):

$$ASR = \frac{NSA}{TNA} \quad (2-9)$$

其中, NSA 表示攻击成功次数, TNA 表示总攻击次数。

保真度使用 L2 距离来衡量, L2 距离指的是原始样本和修改后样本之间的欧氏距离, 这个指标能够在一定程度上说明流量数据的真实程度。对于一个映射到 n 维空间的流量数据, 经过对抗攻击后所得到的对抗流量 $X' = [x'_1, x'_2, x'_3, \dots, x'_n]$, L2 距离保真度 L2_Fidelity 定义为公式(2-10):

$$L2_Fidelity = \sqrt{(x_1 - x'_1)^2 + (x_2 - x'_2)^2 + \dots + (x_n - x'_n)^2} \quad (2-10)$$

2.6 本章小结

本章首先介绍了网络入侵检测技术, 其次介绍了常见的入侵检测构建方案, 包括机器学习和深度学习方案, 然后介绍了有关白盒对抗攻击方案和黑盒对抗攻击方案的分类和具体实施方案, 最后介绍了两个本文用到的网络流量公开数据集和涉及到的评价指标。

第3章 基于 MSM 的黑盒对抗攻击威胁框架

3.1 引言

在实施黑盒对抗攻击的方案中，基于对抗攻击迁移性的方案是其中的一类，因为相似的决策模型之间使用对抗攻击方案产生的对抗样本，可以对彼此模型实施有效的攻击^[70]，因此对代理模型实施对抗攻击，并进一步产生对抗流量迁移到黑盒入侵检测模型上是一种常见方法。然而在进一步限制源流量数据量前提下，难以让代理模型具有和黑盒模型相似的决策能力。不断地修正源流量数据并通过黑盒入侵检测提供的标签来探测决策边界是一种有效的手段，因此需要实施有效的数据增强手段辅助代理模型的训练。

本章的主要工作有四点，1.实施了基于 Tabnet 网络的流量攻击检测方法，研究了该模型在多分类下的流量检测，并进行类别不均衡性矫正。2.根据入侵检测中流量数据的特性提出了 MSM(Mixup & Surrogate Model)方案，这是一种基于 mixup 数据增强辅助代理模型训练的方案，该方案可以有效的帮助代理模型具有和黑盒模型相似的决策能力，此项工作为开展对抗攻击迁移提供了研究基础。3.证明基于 mixup 数据增强方案能够避免特征边界值聚集造成的问题。4.实施了 MSM 方案来生成代理模型，并通过实验说明了该方案的有效性。

3.2 MSM 网络流量黑盒对抗攻击威胁模型

假定在一个黑盒的环境中部署黑盒对抗攻击，该环境中具有入侵检测系统A，攻击方仅能对入侵检测系统A通过修改输入 x 得到输出结果（即通过不断修改输入的流量数据，得到判定为正常或者异常的决策结果）。攻击方无法得到模型的具体细节，包括但不限于决策网络的组织结构，损失函数，训练的 batchsize 以及 epoch 等详细内容。此外，攻击者仅能获取到一定数量的用于训练黑盒模型的训练数据。本章的方案限制了攻击方掌握的数据集原始数据的数量以及入侵检测模型的信息，从而限定本方案是完全黑盒的方案。

实施基于 MSM 的黑盒对抗流量威胁框架如下：

1. 攻击者首先需要窃取部分关于构建入侵检测系统的训练数据 D_1 ，对需要攻击的

内部网络进行流量访问。

2. 通过 mixup 流量数据增强的方案对训练数据 D_i 进行数据增强得到 D_{i+1} 。
3. 经过输入以及反馈的标签重新构建数据集 D_{i+1} 。（首次访问训练数据标签不更改，其他轮次使用入侵检测系统反馈的标签）
4. 通过训练数据 D_{i+1} 来训练本地的可提供梯度信息的代理模型 S_{i+1} 。
5. 使用白盒对抗攻击方法攻击代理模型 S_{i+1} 。（入侵检测系统无法提供梯度信息，直接对其使用白盒对抗攻击的方案不适用。因而借助代理模型 S_i 提供梯度信息进而部署对抗攻击）。
6. 迭代 2-4 步 t 次。
7. 将代理模型的使用对抗攻击产生的流量数据在原入侵检测系统 A 中测试结果。

所述 MSM 威胁框架中涉及的训练代理模型过程示意图，如图 3-1 所示：




图 3-1 MSM 黑盒对抗攻击威胁框架

本章核心任务是构建代理模型 S_t ，让其具备和黑盒的入侵检测模型相似的决策边界，即 $S_t \approx A$ ，由于对抗攻击具备迁移性，目前大量领域内相关研究都借助于对抗攻击的迁移性，如文献^[70]。就基于此展开研究。

算法 3.1 描述了所述 MSM 威胁方案的算法设计。对于实施该方案之前，需要规定代理模型迭代的次数 t ，在有效的时间内获得决策能力更强的代理模型是一项重要的研究工作，获取原始的流量数据 D_1 ，在 i 次迭代过程中使用 mixup 进行数据增强获得 D_i ，

以及可供提供流量标签类型的黑盒入侵检测模型 A 。MSM 威胁方案对于攻击者来说最后可以获得代理模型 S_t ，由于代理模型的类型是攻击者自己定义的，因此可以获取详细的模型参数信息，以及获得代理模型下生成的对抗攻击产生的流量数据 X_t 。

算法 3.1: MSM 黑盒对抗攻击威胁方案

输入: 迭代次数 t ，初始训练数据 D_1 ，仅能提供标签的入侵检测系统 A

输出: 对抗攻击产生的流量 X_t ，代理模型 S_t

1. **For** $i = 0$ **to** t **do**
 2. 使用 $mixup$ 方案扩充 D_i 从而得到 D_{i+1} ;
 3. 将 A 对 D_i 中流量数据的预测结果替换 D_i 对应流量数据原本标签;
 4. 使用 D_i 训练 S_i ;
 5. **End For**
 6. 使用白盒攻击对 S_t 进行攻击;
 7. 得到对抗流量 X_t ;
 8. 将 X_t 迁移到 A 中;
 9. **Return** X_t, S_t
-

限制敌手获得的初始样本数量是本文的重要前提之一，而直接通过有限的流量数据训练一个和黑盒模型决策边界相似的模型较难实施，因此需要使用数据增强方案来扩充流量数据，进而训练一个代理模型以供实施对抗攻击。本章的核心任务是设计并构建一个近似和黑盒对抗攻击相似的代理模型。

3.3 基于 mixup 的流量数据生成方案

数据增强的本意是通过扩充样本量来解决样本不足带来的问题，例如模型欠拟合，样本不均衡性的问题。在本文中，由于限制了攻击者的能力，其中包括获取原始流量的能力。因此变相将问题呈现为：攻击者缺少充足的训练数据来训练代理模型，进而无法通过迁移对抗攻击来实施黑盒的对抗攻击方案。故而在本节中，解决的问题是：使用合适的方法来解决样本缺少问题，进而避免代理模型出现欠拟合，并且采样更多的样本，使代理模型和黑盒模型更相似的决策边界和决策能力。为此，本节提出了基于 mixup 的网络流量数据增强方案^[72]，该方案可以有效避免边界值聚集带来的越界问题，本节末对此进行了定理及其推导证明。

mixup 数据增强方案是一种基于邻域风险最小化的数据增强方法，本章改进了标签

来源，并将改进后的方案结合到网络流量的数据增强问题整体流程中，对于涉及到的频域分布表达式如公式(3-1)所示。

$$\mu(\tilde{X}, \tilde{Y} | X_I, Y_J) = \frac{1}{n} \sum_j^n E_{\lambda} [\delta(\tilde{X}, \tilde{Y})] \quad (3-1)$$

其中， $\tilde{X}$ 和 $\tilde{Y}$ 如公式(3-2)和公式(3-3)所示：

$$\tilde{X} = \lambda X_I + (1 - \lambda) X_J \quad (3-2)$$

$$\tilde{Y} = \lambda Y_I + (1 - \lambda) Y_J \quad (3-3)$$

对于任意一个生成的流量数据 $\tilde{X}$ ，通过 X_I 和 Y_J 这两个已有的流量数据生成的， $\tilde{Y}$ 表示新生成数据的标签，在本章工作中，不应用公式(3-3) $\tilde{Y}$ 来获取标签，而是新生成的虚拟流量数据 $\tilde{X}$ ，通过黑盒的入侵检测模型来赋予标签。因此实际虚拟流量数据 $\tilde{X}$ 对应的标签数据 $\tilde{Y}$ 的计算如公式(3-4)所示：

$$\tilde{Y} = A.predict(\tilde{X}) \quad (3-4)$$

上述公式(3-2)中，从贝塔分布中随机采样一个参数 λ ，即 $\lambda \sim Beta(\alpha_1, \alpha_2)$ ，考虑到任取两个流量数据的随机性，在此规定 $\alpha_1 = \alpha_2$ ，其中 $\alpha \in (0, \infty)$ 。 (X_I, Y_I) 和 (X_J, Y_J) 下标表示分别取自不同的数据的特征向量。

算法 3.2 描述本章提出的基于 mixup 的网络流量数据增强方案。

算法 3.2: 基于 mixup 的网络流量数据增强

输入: 任意一次用于训练代理模型 S_i 的流量数据集 D_i ，参数 α

输出: 经过数据增强后的流量数据集 D_{i+1}

1. //迭代以得到两倍于现有的流量数据
 2. **For** $i = 0$ **to** $D_i.length$ **do**
 3. //从现有数据集合 D_i 中随机放回抽取两个流量数据
 4. $X_I, Y_I = Randomselect(D_i)$;
 5. //通过 mixup 方法产生新的流量数据
 6. $\tilde{X} = mixup(X_I, Y_I, \alpha)$;
 7. //通过黑盒入侵检测 A 预测 $\tilde{X}$ ，得到标签 $\tilde{Y}$
 8. $\tilde{Y} = A.predict(\tilde{X})$;
 9. //将 $\tilde{X}$ 的标签替换为 $\tilde{Y}$ ，并存入集合 new 中
 10. $new.append(\tilde{X}, \tilde{Y})$;
-

11. //集合 new 和流量数据集 D_i 合并得到 D_{i+1}

12. $D_{i+1} = new \cup D_{i+1}$;

13. **Return** D_{i+1}

有关贝塔分布对流量数据处理的宏观情况，对于不同的 α ，对应的 λ 取值的概率密度函数，本节在 $[0,1]$ 区间均匀设置了 100 个点，共测试了五组 α 取值，分别是 0.1、0.5、1.0、2.0、5.0。如图 3-2 所示， α 取多个值，关于采样 λ 的概率密度函数随不同 α 取值下的函数图像。





图 3-2 α 取不同值所对应 λ 取值的概率密度函数

以 $\alpha=0.5$ 为例，对于任意两个流量数据其 $[0.4,0.6]$ 曲线的积分面积将最大，因此 λ 取值落在 $[0.4,0.6]$ 之间的概率最大，那么此时对于新生成的流量数据 $\tilde{X}$ 则更有可能像两者折中的表示。

当 α 取值 <1 时， λ 取值的概率密度函数呈现“中间低，两边高”的形态， α 的值越小越会呈现这种趋势， λ 作为公式(3-2)中系数，此时获得的生成流量更大可能和两侧某一个流量更像；当 α 取值 >1 时，分布呈现“中间高，两边低”的形态， α 的值越大越会呈现这种趋势， λ 作为系数此时获得的生成流量更有可能保持两者共同特点，会导致流量数据结合两者共同特点；当 α 取值 $=1$ 时， λ 的分布呈现“中间和两边一样高”的形态， λ 作为系数获得的生成流量会出现上述两者任意形态，不确定性最强。

上述方案可以进行更快的模型收敛以促使代理模型达到较强的决策能力。如图 3-3 所示，对于决策边界两侧的样本，其标签分别为 1，2。对应蓝色和黄色的点，对于新生成的点，可能由标签相同的数据生成，也有可能由不同的标签生成（决策边界上的



基于 `mixup` 的网络流量数据增强方案可以避免边界值聚集带来的越界问题，此处边界值聚集，指的是流量数据中特征大量聚集于归一化的边界 0 或者 1，而不是均匀分布。例如在 NSL-KDD 数据集中取了一条流量数据：

可以发现该流量特征存在大量的 0 值，后续工作中对该流量数据将其处理至分类器可处理格式也同样如此，0 值对于归一化[0,1]区间是最小值，即对于任意神经网络的输入都存在大量稀疏的情况。对于归一化[0,1]区间内的结果，大量特征聚集于边界值 0 上，该情况就是边界值聚集情况。

定理： 基于 mixup 的数据增强方案可避免边界值聚集造成的越界现象。

中国知网 <https://www.cnki.net>

由于 λ 为概率密度函数积分, 故 $\lambda \in (0,1)$, 恒成立。

① 对于下界 $\tilde{x} \geq 0$, 假设 $\tilde{x} < 0$, 那么对于 $\tilde{x} = \lambda x_i + (1 - \lambda)x_j < 0$ 。

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j = \lambda(x_i - x_j) + x_j < 0$$

因为 $x_i > x_j$, 且 $\lambda > 0$, 故 $\lambda(x_i - x_j) > 0$, 又因为 $x_j \geq 0$, 因此 $\lambda(x_i - x_j) + x_j > 0$, 假设 $\tilde{x} < 0$ 不成立, 故 $\tilde{x} \geq 0$ 。

② 对于上界 $\tilde{x} \leq 1$, 假设 $\tilde{x} > 1$, $\tilde{x} = \lambda x_i + (1 - \lambda)x_j = \lambda(x_i - x_j) + x_j > 1$ 。

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j = \lambda(x_i - x_j) + x_j > 1$$

移项 $\lambda(x_i - x_j) > 1 - x_j$, 由于 $(x_i - x_j) > 0$, 故 $\lambda > \frac{1-x_j}{x_i-x_j}$, 由于 $1 - x_j \geq x_i - x_j$, 因此 $\frac{1-x_j}{x_i-x_j} \geq 1$, 即 $\lambda \geq 1$, 然而 $\lambda \in (0,1)$, 因此假设不成立, 故 $\tilde{x} \leq 1$ 。

综上所述对于任意新生成的流量数据任意位置特征 $\tilde{x}$, $\tilde{x} \in [0,1]$, 因此不论如何迭代和选择新的流量样本都不会出现越界问题。

3.4 基于 Tabnet 的黑盒入侵检测模型的构建

如何提升 DNN 对于网络流量数据的识别能力是一项重要任务, 传统的方案对于网络流量这类表格数据的表现通常不如树类型的分类器, 例如梯度提升决策树(Gradient Boosting Decision Tree, GBDT), 随机森林(random forest), xgboost (eXtreme Gradient Boosting)等。为了更好的评估 MSM 框架的有效性, 为此需要使用推理能力更强的一种分类模型。

Tabnet^[73]是一种专门用于处理表格数据的网络, 由 2021 的 Google 提出, 其他类似的决策流型的网络经常出现在专业的数据挖掘竞赛中, 由于从数据类型角度来看, 网络流量的数据集也是表格数据, 并且一般的基于决策流的模型, 在处理入侵检测流量数据中也有很强的表现。

3.4.1 整体模型结构

Tabnet 模型为多步过程, 通过特征变换 (Feature transformer) 和权重系数 Mask (Attentive transformer), 一部分得到输出结果 ReLU 加权, 另一部分得到当前步骤的输出向量, 最终将多步输出向量累加之后, 利用全连接层做一次变换, 得到最终的输出, 完成预测。

如图 3-4 所示, 通过决策的边界 a 和 d 值将不同的数据划分为四个区域, 进而根据

不同的特征来预测其标签。图 3-4 以及图 3-5 均来源于 Tabnet 原文，该网络设计的意图是为了让神经网络的组成模拟决策型的处理过程。




图 3-4 决策流形分类示意




图 3-5 Tabnet 的编码器结构

对于 Tabnet 编码器设计如图 3-5 所示，不同于进行全局的归一化操作，而只是应用批量归一化(BN)。将 D 维特征 $f \in R^{B \times D}$ 传递给每个决策步骤，其中 B 来规定批量的大小。Tabnet 共有多轮决策。第 i 步输入来自第 $(i - 1)$ 步的处理后的信息，以决定使用哪些特征，并输出处理后的特征表示，以聚合到总体决策中。

3.4.2 转换器模块

图 3-6 中的关注转换器模块(Attentive Transformer)负责特征选择，它是由全连接层、批量正则化、以及稀疏正则化层组成。该模块主要意图是通过对重要特征的稀疏选择，每轮决策下的学习不再浪费在无关特征上，因此模型变得更有效率。如图 3-6 所示，是

Tabnet 中的(Attentive transformer)模块。




图 3-6 Tabnet 的 Attentive Transformer 模块

该模块用来获取图 3-6 中的 $mask$ ，对于一个可学习的 $mask$ 为 $M[i]$ ，它是通过对于之前获取的 $a[i-1]$ 次特征来计算的，对于 $M[i]$ 的公式表达式如公式(3-5)所示：

$$M[i] = \text{sparse max}([p[i-1] \cdot h_i(a[i-1])]) \quad (3-5)$$

其中 Sparsemax 是 softmax 的更改版本，Sparsemax 的意图是希望选择更为稀疏的特征。

Sparsemax 的函数表达式为公式(3-6)：

$$\text{sparse max}(t) = \begin{cases} 0 & \text{if } t \geq 1 \\ -t & \text{if } t \leq 1 \\ \frac{(t-1)^2}{4} & \text{if } -1 < t < 1 \end{cases} \quad (3-6)$$

$P[i]$ 是先验尺度项(prior scale term)，它通过设置一个 γ 的松弛参数来控制特征被使多个决策伦次下的使用。有关 $P[i]$ 的定义表达式为公式(3-7)：

$$p[i] = \prod_{j=1}^i (\gamma - M[j]) \quad (3-7)$$

3.4.3 特征转换模块

特征转换模块(Feature Transformer)负责特征处理，该模块负责处理已过滤的特征，然后拆分给总决策输出和下一层输出，如图 3-7 所示的 Feature Transformer 模块，其中各决策共享步骤(Shared Across Decision Steps)负责计算特征的共性，并将图 3.6 中向右输出数据流，决策独立步骤(Decision Step Dependent)负责计算特征的特性，向上通过激活函数 ReLU 得到最终决策。

该模块是通过 FC+BN+GLU (gated linear unit)的排列组合而成，一些层之间乘 $\sqrt{0.5}$ 进行残差连接， $\sqrt{0.5}$ 是为了确保网络不会变动太大，帮助稳定学习。




图 3-7 Tabnet 的 Feature Transformer 模块

3.4.4 设计流程

本章所实施 Tabnet 充当黑盒入侵检测模型，对流量预测的整体设计，如下流程：首先通过流量数据的预处理，将数据集内的流量数据，进行如下预处理：经过数值化、归一化、标准化操作。其次，重采样数据集以减弱样本不均衡性带来的少数类识别能力不足的问题，通过相关参数预设 Tabnet 充当分类器，将相同预处理方式流量数据划分训练集和验证集和测试集，训练好初始的黑盒入侵检测模型，观察相关流量数据分类情况，根据不同类别的流量数据预测能力重新调整各类别流量的训练权重，不断的调整最终获得 Tabnet 黑盒入侵检测模型。

上述流程的整体实施框架如图 3-8 所示：




图 3-8 Tabnet 黑盒入侵检测模型整体架构

3.5 实验设计与分析

本节使用网络流量数据集来验证本章实验的有效性，实验采用的数据集为 NSL-KDD 数据集。为了验证本节实验采用机器学习框架 Sklearn，深度学习框架 pytorch 等，使用 Python 编程，Python 版本为 3.7，实验环境的硬件方面主要采用的配置如表 3-1 所示。

表 3-1 实验配置说明

实验配置	配置信息
CPU	Intel(R) Core(TM) i5-11400H @ 2.70GHz
显卡	NVIDIA GTX3060 8G GDDR5
内存	16G
环境	Windows 11 64 位操作系统
工具	Pycharm+Anaconda

3.5.1 数据预处理

由于原始流量数据包含非数值数据，并且数据中存在不准确和非法的值等特殊情况。故而需要纠正或者删除非法数值，通过规整数据，以达到数据整体质量的提高来让模型具有更好的推理能力，使得实验结果更加真实准确。

数据预处理是数据分析和机器学习中至关重要的步骤，主要包括数据清洗、数据集成、数据变换和数据规约这四个核心内容。在这些步骤中，需要采用多种具体的处理手段和步骤，以确保数据的质量和一致性。

对于网络流量数据集而言，其特征类型主要包括字符型和数值型。数值型数据进一步细分为离散型和连续性，而由于网络攻击流量的复杂性，导致其数据范围存在较大差异。为了有效应对这一挑战，本章在实验中采用了数据变换的方法，具体包括数值化、标准化和归一化。

在数据变换阶段，数值化的过程将字符型特征转换为数值型特征，以便于后续模型的应用。标准化则用于对数值型特征进行缩放，使其具有零均值和单位方差，有助于提升模型的收敛速度和性能。同时，归一化将数值型特征缩放到指定范围内，以防止某些特征对模型产生过大的影响。

这一系列的数据变换不仅有助于规范数据集中各个数据特征，提高了数据集的质

量，还为后续实验奠定了坚实的基础。通过数据预处理，能够更好地理解和利用网络流量数据，从而为后续分析和建模工作提供更为可靠的数据支持。

(1) 流量数据数值化

在本文的网络流量领域的数据集中，包含协议类型、目标站点服务类型、连接状态等非数值化数据，例如 NSL-KDD 数据集中，<Protocol Type, Service, Flag>字段为非数值化数据。在本文所述数据集中，使用特征哈希(Feature Hash)的方法来处理这个问题，一方面不希望类似于独热编码的方式将特征扩充过度，另一方面希望有效的遏制此类数据集中的特征类别不均问题。

(2) 流量数据标准化

在本文的网络流量数据集中，不同特征的数据范围不相同，有些特征数值相差较大，如果不做处理直接使用，会使得数值较大的数据在综合指数中的作用被主观放大。为了缩小这些差距，保证结果可靠性，需要对每条数据进行标准化操作，进而达到统一的度量。

对于任意一个流量数据 $X(x^1, x^2, \dots, x^n)$ ，对于第 k 个特征属性的平均值 $\overline{x^k}$ 和平均误差 S^k ，计算该样本空间下的每个特征属性平均值如公式 3-8 所示，平均误差如公式 3-9 所示：

$$\overline{x^k} = \frac{1}{n} \sum_{i=1}^n x_i^k \quad (3-8)$$

$$S^k = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i^k - \overline{x^k})^2} \quad (3-9)$$

那么，对于标准化后的第 t 条数据的第 k 个位置特征属性如公式 3-10：

$$T_i^k = \frac{x_i^k - \overline{x^k}}{S^k} \quad (3-10)$$

在本文实验中，使用标准化公式的方法，将数据映射到 $[-5,5]$ 之间。这相对于映射到 $[0,1]$ 上可以更为有效地为对抗攻击提供更大的扰动空间。

3.5.2 Tabnet 超参数设置以及不平衡性矫正

本小节实验统一采用 3.5.1 中有关 NSL-KDD 数据集的预处理方案，并实施五分类，实验过程中对于 Tabnet 所用的重要参数，以及参数含义及其取值如表 3-2 以及表 3-3 所

示。

表 3-2 Tabnet 实验中所列的模型参数

模型参数	含义	取值
n_d	决策预测层的宽度	8
n_a	每个 mask 的注意力嵌入宽度	8
gamma	掩码中特征重用的系数	1.3
n_independent	每个步骤的独立门控线性单元图层数	2
n_shared	每个步骤的共享门控线性单元数	2
momentum	批量归一化的动量	0.02
lambda_sparse	论文中提出的额外稀疏性损失系数	0.001

表 3-3 Tabnet 实验中所列的拟合参数

拟合参数	含义	取值
optimizer_fn	Pytorch 优化器函数	torch.optim.Adam
loss_fn	交叉熵损失函数	Cross Entropy
max_epochs	训练周期	200
batch_size	每批处理的样本数	1024
weights	不同标签数据训练权重	根据样本不平衡性调节




图 3-9 Tabnet 在验证集上的损失曲线和准确率曲线

如图 3-9 所示，在验证集上的 Tabnet 作为入侵检测模型的 loss 曲线，发现模型在 75 到 90 之间表现最好且最稳定，而 epoch=110 之后，准确率有所下降并不断震荡，这说明出现了过拟合现象，而对于 epoch=30 以及 epoch=50 阶段表现不稳定，因此后续中调整了 Tabnet 的训练周期。

在实验过程中，还发现了黑盒模型对少数类出现了样本不均衡性，对于部署者来说应当及时发现并消除样本不均衡性问题。本节对于这个问题使用了两个方案：1.通过调整了 U2R(User to Root)和 R2L(Remote to Local)两类数据的训练权重，实验过程中使用 $w=\{2,1,5,4,1\}$ 的权重来训练数据。2.重采样用来训练黑盒模型的训练集，从而避免了样本不均衡性问题。后续实验中遇到类似问题都是通过以以上两种类别不平衡方案处理的黑盒模型来进行后续实验。图 3-10 是经过样本不均衡性问题处理后的 Tabnet 混淆矩阵。




图 3-10 样本不均衡问题处理后的混淆矩阵

3.5.3 Tabnet 入侵检测模型对比

本节将 Tabnet 与其他常见的入侵检测模型进行对比，用以测试 Tabnet 方案的优势，本节测试了决策树方案、高斯朴素贝叶斯、以及 SVM 作为本节的对比。本节所采用的训练集与 3.5.2 节一致，都经过数据集重采样的方案来进行实验，对于决策树方案机器学习模型采用的参数如表 3-4 所示：

表 3-4 决策树所采用的参数

参数	含义	取值
criterion	用于衡量特征的质量的函数	gini
min_samples_leaf	叶节点所需的最小样本数	1
min_samples_split	进行划分所需的最小样本数	2
max_features	在寻找最佳划分时要考虑的特征数量	None
max_leaf_nodes	叶节点的最大数量	None

对于朴素贝叶斯方案构建入侵检测模型时所采用的参数如表 3-5 所示：

表 3-5 高斯朴素贝叶斯所采用的参数

参数	含义	取值
priors	类的先验概率	None
var_smoothing	用于保证计算稳定性的方差平滑参数	1e-9

对于 SVM 方案构建入侵检测模型时所采用的参数如表 3-6 所示：

表 3-6 支持向量机所采用的参数

参数	含义	取值
C	正则化参数	1.0
kernel	核函数类型	径向基函数
gamma	核函数的系数	scale
shrinking	是否使用收缩启发式	True
max_iter	最大迭代	不限制

根据表 3-4，表 3-5，表 3-6 所示的上述机器学习方案构建入侵检测模型，与本文提出的基于 Tabnet 方案进行对比，如图 3-11 显示决策树方案、高斯朴素贝叶斯、以及 SVM 方案有关准确率、精确率、召回率、以及 F1_score，结果显示对于入侵检测的流量数据进行分类，在相同的特征工程前提下，所述的四种分类方案在 NSL-KDD 上的表现都时 Tabnet 作为黑盒模型最好，因此本文提出的基于 Tabnet 充当黑盒入侵检测方案具备有效性。




图 3-11 Tabnet 与对比方案的四个评价指标的表现

3.5.4 MSM 下代理模型实施

为了验证本实验中 mixup 方法的有效性, 本节测试了使用不同的 mixup 中的 α 的取值以生成的不同的 β 分布, 进而生成的不同的数据集训练代理模型, 使其具有和黑盒模型相类似水平的推理能力, 从而根据对抗攻击迁移性原理, 为后续的工作提供基础支撑。需要说明的是: 本小节训练的代理模型通过 3.3 节方案生成的虚拟流量训练代理模型并不影响最终结果, 对于代理模型更重要的是通过数据增强方案探测更多的样本点来拟合黑盒模型的决策边界。后续实验所有有关于评价指标的数据都是在相关数据集内抽取的原始数据, 而不是通过数据增强后的数据, 以此保证实验的真实有效。

在此处使用 3 层 MLP 作为代理模型, Tabnet 作为黑盒模型来进行实验。使用 3.5.2 参数训练 Tabnet 作为黑盒模型, 选取初始的 500 条流量数据, 每个攻击类别各取 100 条流量并实施不放回的抽样, 那么对于构造的代理模型 S_i 其随着迭代次数以及在 30% 测试集上的 Recall 表现如图 3-12 所示。




图 3-12 α 取值对训练代理模型的影响

实验结果可以发现, 对于任意的 α 取值的方案都可以生成新的流量样本, 来促使代理模型推理能力增强, 这说明 3.3 节提及的方案具备有效性。但是选择不同的 α 值对代理模型的表现存在一定差别, 对于选择 $\alpha > 1$ 的情况下, 使用 mixup 方案生成的流量数据更难以拟合真实情况下的流量数据, 因为这种情况下进行代理模型训练 recall 指标相对于其他情况较差, 因此推荐使用 $\alpha < 1$ 的值来使用 mixup 方案。对于 $\alpha < 1$ 的情况中, 本实验发现 $\alpha = 0.1$ 条件下训练的代理模型, 比起其他四组数据是最好的。当 $\alpha = 0.1$ 时, mixup 生成的样本 $\tilde{X}$ 更像真实流量。因此得出以下结论: 攻击者要达到代理模型和黑盒

模型决策边界相似的目标，更应该在真实流量（假定数据集中流量是真实的）附近采样，而不是选择远离采样点的地，因此应该选取 α 的值更小的情况。

对于实施代理模型评价指标瓶颈可能与 MLP 层数有关，为此本章合理的扩充了 MLP 的层数，结果 recall_score 以及 f1_score 这两种评价指标 MLP 层数更深的网络在随着数据增强方案后呈现出：MLP 层数越深，效果更好的趋势。同时对于深度较深的 MLP 其评价指标峰值也相对延后，如图 3-13，图 3-14 表示：




图 3-13 不同网络深度与随迭代次数的召回率变化




图 3-14 不同网络深度与随迭代次数的 F1_score 变化

上述结果说明，伴随着网络层数的加深，MSM 威胁框架下生成的代理模型，其评价指标的瓶颈伴随着网络深度增加而上升，此外，需要更多迭代次数才能到达这个瓶颈。因此在后续工作中也适当的增加了代理模型的全连接层深度。

3.5.5 mixup 数据增强对比方案

本小节通过不同的数据增强方案对比 mixup 方案来测试对代理模型的时间功耗以及评价指标的影响。基于 mixup 的代理对比了基于雅可比矩阵增幅的方案、基于线性

插值的方案、以及对照组（无数据增强方案，训练更多 epoch）。

时间开销方面，由于基于雅可比矩阵的方案需要对每个向前求导，花费时间很长，本节选择了初始每类流量共计 50 条，共计 250 条流量数据。对于每个代理模型训练 20 个 epoch。

对于本小节设计的四种方案，选择迭代 6 次的不同方案的时间开销如图 3-15 所示。




图 3-15 数据增强方案时间功耗对比

实验中发现，只有基于雅可比矩阵的方案非常耗时，其他的方案时间功耗基本差不多，对于数据增强的代码部分，几乎都是 10 秒以内完成了 7 次迭代。图 3-15 其他曲线都在对照组曲线附近，并被红色的对照组曲线覆盖。

对于代理模型训练 10 次后其评价指标精确率、准确率、召回率、F1 评分如图所示如图 3-16 所示。




图 3-16 不同数据增强方案的对比

可以发现，基于 mixup 的方法在上述四个评价指标中均高于其他实验组，对于所

述四种方案中任意一种方案来看，精确率和召回率表现良好，但是对于准确率和 $f1_score$ 表现较差，后续工作中增多初始获得的用于训练代理模型的初始数据集 D_1 ，可有效提升这两个评价指标。图 3-16 上的结果表明，通过 mixup 方案来训练代理模型的方法，对比常规方案有着比较显著的优势。

3.6 本章小结

本章对 MSM 黑盒对抗攻击框架进行了设计和实现，该方案优化了训练代理模型的数据增强方案，针对原本的基于雅可比矩阵方案，本章论述在入侵检测领域中的场景特殊约束问题，以 Tabnet 作为黑盒模型充当入侵检测模型，并借鉴 mixup 数据增强方案来辅助代理模型的训练。

相关结果表明，Tabnet 作为黑盒入侵检测模型可以将其推理能力蒸馏给代理模型，mixup 数据增强方案能够好的帮助提高代理模型学习黑盒模型的能力，能够具备相对较强的推理能力。本章的工作为对抗攻击迁移问题提供了研究基础。

第4章 对抗流量及其 MSM 下的迁移性

4.1 引言

对抗攻击来源于计算机视觉领域，图像数据与流量数据的数据格式存在差别，如何实施对抗攻击方案以产生对抗流量是一项重要的任务，现有的对抗流量的方案通常未划定统一的特征处理方案，然而不同的特征工程方案对流量数据实施对抗攻击带来的影响非常大。

在本章工作中，1.使用相同的特征工程处理流量数据，实施了 FGM，PGD，C&W，SLIDE 四种对抗攻击方案来产生对抗流量，通过从保真度、生成时间指标上来评估这四类白盒对抗攻击方案。2.本章将上述四种对抗攻击产生的对抗流量进一步使用 MSM 方案拓展到 xgboost 和 GBDT 上来测试结果，并在 NSL-KDD 以及 UNSW-NB15 这两个数据集上验证了结果。3.通过 t-SNE 方案以实现了网络流量数据的低维度表示，实现不同类型流量数据的低维可视化，对比不同对抗攻击方案产生的对抗流量对于原始流量数据的低维表达区别，来直观的感受不同类型对抗攻击产生的流量数据的失真程度。

4.2 对抗流量实施方案

在本章的工作中，通过白盒对抗攻击 FGM，PGD，C&W，SLIDE 四种对抗攻击方案来产生对抗流量。相关的流量预处理手段与第三章工作相同，以特征空间的流量数据作为对抗攻击起点进行迭代。

4.2.1 FGM 对抗流量实施方案

FGM(Fast Gradient Method)，与 FGSM 区别在于使用了 L2 范数进行归一化，这种方式可以更好的约束对于原始样本的修改，而不是符号函数来进行约束，更进一步的讲，可以具有更小的保真度(更小的 L2 距离)，原始流量数据更加像真实数据。FGM 中，扰动 η 定义为公式(4-1)：

$$\eta = \varepsilon \frac{g}{\|g\|_2} \quad (4-1)$$

其中， $g = \nabla_x J(\theta, x, y)$ ， ε 表示设置的步长， $J(\theta, x, y)$ 为损失函数， $\nabla_x J(\theta, x, y)$ 表示对 x 求偏导， $\|g\|_2$ 表示对 g 进行 L2 距离的正则化。

修改原始流量的公式，对于修改后流量数据 x' ， $x' = x + \eta$ 。因此对于 FGM 施加扰动的如公式(4-2)所示：

$$x' = x + \varepsilon \frac{\nabla_x J(\theta, x, y)}{\|\nabla_x J(\theta, x, y)\|_2} \quad (4-2)$$

算法 4.1 描述了本章使用 FGM 对抗攻击方案来产生对抗流量的算法：

算法 4.1： 基于 FGM 的对抗流量产生方案

输入： 流量数据 x ，设置扰动步长 ε ，训练后的入侵检测模型的损失函数 $J(\theta, x, y)$

输出： FGM 方案下的对抗流量 x'

1. $g = \nabla_x J(\theta, x, y)$ //使用目标函数 $J(\theta, x, y)$ 对输入流量数据 x 求偏导
 2. $\eta = \varepsilon \frac{g}{\|g\|_2}$ //计算扰动，并通过 L2 正则化
 3. $x' = x + \eta$ //得到最终的对抗流量 x'
 4. **Return** x'
-

4.2.2 PGD 对抗流量实施方案

PGD(Projected Gradient Descent)，本章使用的 PGD 方案同样是 L2 范数进行约束，该方案是迭代产生的，对于任意一次施加 PGD 迭代对抗攻击后的流量表达为公式(4-3)：

$$x'_{t+1} = \text{Clip}_{x, \varepsilon}(x'_t + \varepsilon \cdot \text{sign}(\nabla_x J(\theta, x, y))) \quad (4-3)$$

公式(4-3)中 ε 、 $\nabla_x J(\theta, x, y)$ 的含义和 4.2.1 节中的一致，此外 Clip 函数表示限制扰动最大限制，即总体扰动的限制。PGD 的设计意图是希望能够多次寻找沿着梯度下降最快的方向往前走，而不是类似于 FGM 和 FGSM 单步迭代一步到位。算法 4.2 描述了如何使用 PGD 对抗攻击方案来产生对抗流量。

算法 4.2： 基于 PGD 的对抗流量产生方案

输入： 流量数据 x ，设置扰动步长 α ，最大扰动 ε ，迭代次数 N ，训练后的入侵检测模型的目标函数 $J(\theta, x, y)$

输出： PGD 方案下的对抗流量 x'

1. $x_{adv} = x$ //初始化对抗攻击
 2. **For** $i = 0$ **to** N **do**
 3. $g = \nabla_x J(\theta, x_{adv}, y)$ //计算损失函数关于当前对抗样本梯度
 4. $\eta = \alpha \cdot \text{sign}(\nabla_x J(\theta, x, y))$ //sign 表示符号函数，取梯度的符号
-

-
5. $x_{adv} = x_{adv} + \eta$
 6. $x_{adv} = \text{Clip}_{x, \varepsilon}(x_{adv})$ // 将扰动裁剪到最大范围内
 7. $x' = x_{adv}$
 8. **Return** x'
-

4.2.3 SLIDE 对抗流量实施方案

SLIDE (Sparse L1 Descent Attack)^[74]旨在通过最小化 L1 范数来产生稀疏的扰动。这种攻击特别适用于需要稀疏扰动的场景，该方案也很适用于流量数据，因为对于流量数据也希望尽可能少的特征修改，这样更容易实施。SLIDE 方案主要是为了修改更少的原始流量的特征数据。算法 4.3 描述本章使用的基于 SLIDE 对抗攻击方案生成的对抗流量。

算法 4.3: 基于 SLIDE 的对抗流量产生方案

输入: 流量数据 x , 设置学习率 α , 最大扰动 ε , 稀疏度参数 λ , 迭代次数 N , 训练后的入侵检测模型的目标函数 $J(\theta, x, y)$

输出: SLIDE 方案下的对抗流量 x'

1. $x_{adv} = 0$ // 初始化对抗攻击
 2. **For** $i = 0$ **to** N **do**
 3. $x_{adv} = x + \delta$ // 计算当前对抗样本
 4. $g = \nabla_x J(\theta, x_{adv}, y)$ // 计算损失函数梯度
 5. $\delta = \delta - \alpha \cdot g$
 6. $\delta = \max_{\lambda}(\delta)$ // 仅保留 δ 中最大的 λ 个绝对值元素，其他元素置为零
 7. **If** $\|\delta\|_1 > \varepsilon$ // 如果扰动 L1 距离大于最大扰动，则进行 L1 约束
 8. $\delta = \varepsilon \cdot \frac{\delta}{\|\delta\|_1}$ // 将扰动裁剪到最大范围内 ε
 9. $x_{adv} = x_{adv} + \delta$
 10. $x' = x_{adv}$
 11. **Return** x'
-

4.2.4 C&W 对抗流量实施方案

C&W (Carlini & Wagner) 对抗攻击方法主要通过优化一个目标函数来生成对抗样本。该方法的目标是在保持对抗样本与原始样本之间的差距尽可能小的同时，迫使模型做

出错误的分类。本方案使用的 C&W 中目标函数如公式(4-4)所示：

$$f(x_{adv}) = \max(\max\{Z(x_{adv})_j : j \neq t\} - Z(x_{adv})_t, -\kappa) + c \cdot \|\delta\|_2^2 \quad (4-4)$$

其中 $Z(x_{adv})$ 表示模型对 x_{adv} 的输出向量， t 是目标类别， κ 是控制置信度的函数， c 是正则化参数。对于盒约束问题，本章使用的方案为梯度截断(Clipped gradient descent)，该方案将超出定义域的样本截断到定义域内相应的边界。本文所用的流量数据映射为 $[-5, 5]$ ，梯度截断如公式(4-5)所示：

$$f(\min(\max(x + \delta, -5), 5)) \quad (4-5)$$

算法 4.4 描述本章使用的基于 C&W 对抗攻击方案生成的对抗流量。

算法 4.4： 基于 C&W 的对抗流量产生方案

输入： 流量数据 x ，设置学习率 α ，最大扰动 ε ，迭代次数 N ，训练后的入侵检测模型的目标函数 $J(\theta, x, y)$

输出： C&W 方案下的对抗流量 x'

1. $x_{adv} = x = 0$ //初始化对抗攻击
 2. **For** $i = 0$ **to** N **do**
 3. $x_{adv} = x_{adv} + \delta$ //计算当前对抗样本
 4. $\delta = \delta - \alpha \cdot \nabla_{\delta} f(x_{adv})$ // $f(x_{adv})$ 定义由公式(4-4)，计算扰动
 5. $x_{adv} = \text{Clip}(x_{adv}, -5, 5)$ //使用盒约束梯度截断进行边界约束
 6. $x' = x_{adv}$
 7. **Return** x'
-

4.3 基于 t-SNE 的对抗流量可视化

t 分布邻域嵌入(t-Distributed Stochastic Neighbor Embedding, t-SNE)，是一种降维的方法，t-SNE 对高维数据的相似度采用高斯分布，而在低维空间采用 t 分布，这有助于解决“拥挤问题”，即在低维空间中保持高维空间中的局部结构。该方案是目前常见的降维方法。由于对抗攻击的意图之一是实施尽可能小的扰动幅度，因此在这一节工作中，希望通过 t-SNE 可视化修改前后的流量数据的低维形式，以直观感受到不同方案的对抗攻击保真程度。

在本节工作中，使用 t-SNE 方案来设计了章节 4.2 中的四种对抗攻击产生的对抗流量的可视化效果，对于本节基于 t-SNE 的对抗流量可视化流程，主要通过五个部分组

成。

1.流量数据预处理：对于任意输入流量数据，进行预处理，将不可处理的网络流量数据集中的数据转化为可处理格式，这部分工作与 3.5.1 中的一致。

2.高维流量数据的相似度计算：t-SNE 的高维空间的相似度依靠高斯分布来转换距离为概率值，这个概率值表示一个点选择另一个点作为其邻居的可能性。高斯分布由公式(4-6)：

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)} \quad (4-6)$$

其中， x_i 和 x_j 表示高维空间的一对流量数据，通过计算它们之间的条件概率 $p_{j|i}$ ，进而表示给定 x_i 情况下 x_j 作为邻居的概率。然后进行对称化计算联合概率 p_{ij} ， p_{ij} 由公式(4-7)：

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2N} \quad (4-7)$$

3.低维流量数据的相似度计算：对于低维空间的一对数据点 y_i 和 y_j ，采用 t 分布来实现，这是一种比高斯分布更加平缓的分布，通过这种方案来计算相似度，进而避免不同的簇产生拥挤。T 分布如公式(4-8)所示：

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}} \quad (4-8)$$

其中， k 和 l 代表来自与不同的流量数据。

4.梯度下降优化：这一步目标是调整低维空间的点的位置，使得低维度和高维度空间的相似度一致，这一部分通过梯度下降来最小化两个空间的相似度分布 KL 散度来实现，对于 KL 散度如公式(4-9)所示：

$$C = KL(P||Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}} \quad (4-9)$$

其中，P 表示高维空间中数据点之间的相似度分布，Q 表示低维空间中数据点之间的相似度分布。对每个数据点 i 使用梯度下降方法来优化低维空间中的点 y_i ，梯度计算公式如公式(4-10)所示：

$$\frac{\delta C}{\delta y_i} = 4 \sum_j (p_{ij} - q_{ij})(y_i - y_j)(1 + \|y_i - y_j\|^2)^{-1} \quad (4-10)$$

5.迭代更新：每次迭代过程中，使用上述梯度更新的方式来更新低维空间的点，直到达到预设迭代次数。

4.4 实验分析

4.4.1 对抗流量可视化

本节实验中，采用第三章中用来训练代理模型最初的 500 条流量数据作为实验的数据，共 5 个流量类型，每个类型 100 条。本节采用了 4.2 中涉及到的四种对抗攻击方案来生成对抗流量，进而可视化不同方案的对抗流量的区别。本节对于 t-SNE 方案的参数设定如表 4-1 所示：

表 4-1 t-SNE 方案的参数设定

参数	含义	取值
n_components	低维空间的维数	2
Perplexity	困惑度，衡量邻域大小的参数	50
learning_rate	学习率，用于控制梯度下降优化过程中的步长	100
Metric	用于计算高维空间中点之间距离的度量	Euclidean
Init	初始化低维空间中点的位置的方法	PCA

本节实验所使用的分类器为 MLP，设定了 5 层全连接层，使用 NSL-KDD 全数据集下的 70%数据作为训练集对网络流量进行五分类的训练。并通过上述 500 条流量数据分别进行算法 4.1，算法 4.2，算法 4.3，算法 4.4 涉及到的对抗攻击，攻击该 MLP 分类器产生对抗流量。

同时，为了清晰的发现各个流量类别的 t-SNE 的低维表示，对于每一类的流量数据进行颜色显示，对于 NSL-KDD 中抽取的这五类流量数据，其标签类型以及颜色标识，如表 4-2 表示：

表 4-2 不同类型流量的颜色设置

流量类别	对应到 t-SNE 可视化图中的颜色
Normal	Cyan(青色)
Dos	Red(红色)
u2r	Purple(紫色)
R2L	Orange(橘色)
Probe attacks	Green(绿色)

使用上述对应的参数和方案，对于原始的流量数据在 t-SNE 方案下的低维表达，如图 4-1 所示：




图 4-1 原始流量数据的 t-SNE 下表达

通常来讲，t-SNE 最终结果在一个簇内具有高度的相似性，这意味着流量数据通常以聚集团的形式存在于低维空间，图 4-1 的结果显示：

对于正常流量，与较多的 R2L 和 U2R 混合成为一个较大的聚集团，同时也有少量的 Dos 类型流量混合在一起。这说明这三类流量数据的低维表达相近。这说明在 t-SNE 的低维表达中，R2L 和 U2R 这两类恶意流量与正常流量统计学特征相似。

对于 Dos 类型的流量的分割非常清晰，大量的 Dos 流量与 Probe attacks 流量混合在一起，形成一个较大的簇，也有一少部分 Dos 流量数据与 Probe attacks 流量混合在图 4-1 的正上方，形成另一个簇。

对于 u2r 类型的恶意流量，它们自身几乎没有过多的聚集，在 t-SNE 的低维表达中，呈现出相对扩散的效果，这说明这类流量之间的相似度比较低。

对于 R2L 类型的恶意流量也是如此，它们的 t-SNE 低维表达其离散程度更强，但是它们中的一部分则呈现出与其他类型流量比较相近的相似度，尤其是正常数据。

对于 Probe attacks 类型的流量，一部分与 Dos 类型等其他流量混杂在一起，另一部分则聚集度相对不明显。

FGM 对抗流量方案设置扰动大小为 0.1；PGD 对抗流量方案步长大小为 0.1，扰动上限为 5，迭代 20 次；SILDE 对抗流量方案步长为 0.1，稀疏度参数 λ 为 10，迭代次数为 20 次；C&W 对抗流量方案迭代次数 20 次，置信度为 0，学习率为 0.005，initial_const 设置为 0.01。对于上述四种对抗攻击方案，在所述 t-SNE 下的低维表达效果，如图 4-2，图 4-3，图 4-4，图 4-5 所示：




图 4-2 基于 FGM 方案产生的对抗流量




图 4-3 基于 PGD 方案产生的对抗流量




图 4-4 基于 C&W 方案产生的对抗流量




图 4-5 基于 SILDE 方案产生的对抗流量

上图整体的数据分布与图 4-1 的差距表明，不同的对抗攻击产生的对抗流量的低维表达存在差异性，可以发现，其中 4-2 显示使用 FGM 产生的对抗流量的 t-SNE 低维表示与图 4-1 正常流量的 t-SNE 低维表示几乎一致，这是由于 FGM 不是迭代的对抗攻击方案，其保真度以及对抗攻击的攻击成功率也相对较低。对于图 4-3、图 4-4、图 4-5 所述的 PGD、C&W、SILDE 对抗攻击方案，其效果来看，PGD 的保真程度最差，与图 4-1 具有很大区别，且不同类型的流量数据分散开来，说明聚集性变差，这与通常情况下的流量数据低维表示有较大出入，这表明使用该方式产生的对抗流量真实度较弱。C&W 相较于其他方案的 t-SNE 低维表达与真实流量区别不大，说明更相近与真实情况。

4.4.2 不同流量类别的对抗攻击敏感度

本节主要测试不同类型流量数据的攻击成功率，由于各个类型的流量数据与对抗攻击的敏感度不一致，因此需要进一步的挖掘。本节主要以 C&W 对抗攻击方案为例。

对于对抗攻击方案 C&W 的相关参数设置如表 4-3 所示：

表 4-3 C&W 方案的参数选择

lr(步长)	Confidence(置信度)	范数	initial_const
0.005	0	L2 范数	0.01
攻击方案的学习率	控制对抗样本生成大小	限制扰动	控制错误预测与扰动幅度平衡

迭代次数从5开始，到30为止。为了直观感受 C&W 攻击的影响，展示迭代5次，迭代11次，迭代17次，迭代23次和迭代30次混淆矩阵如图4-6、图4-7、图4-8、图4-9、图4-10所示，混淆矩阵中的行列标号0-4分别表示 Normal、Dos、u2r、R2L、Probe attacks 五类流量。




图 4-6 迭代 5 次结果




图 4-7 迭代 11 次结果




图 4-8 迭代 17 次结果




图 4-9 迭代 23 次结果




图 4-10 迭代 30 次结果

可以发现 C&W 对抗攻击方案迭代的后期对于 Dos、u2r 以及 R2L 这三类流量敏感而对 Normal 和 Probe attacks 不敏感（表现为矩阵中主对角线五个位置对应颜色由深度

变浅的程度), 进一步测试了 SLIDE 攻击方案以及 PGD 攻击方案, 将这两种方案都迭代 30 次, 也出现了不同类型流量敏感度不同的情况。如图 4-11、图 4-12 所示:




图 4-11 SLIDE 攻击方案




图 4-12 PGD 攻击方案

对于这两种对抗攻击方案实施算法原理与 C&W 并不完全一致, 但都表现出 U2R(User to Root)和 R2L(Remote to Local)这两类更加容易受到对抗攻击的威胁。因此不同类型恶意流量对于对抗攻击方案敏感程度不完全相同。

测试每一类流量数据单独的攻击成功率, 攻击迭代到第 30 次的效果如表 4-4 所示:

表 4-4 C&W30 次迭代的攻击成功率

流量类型	Normal	Dos	u2r	R2L	Probe attacks
攻击成功率	29.8%	60.3%	65.7%	63.1%	28%

可以发现有关 u2r 类攻击的攻击成功率最高, 而且在这个过程中明显发现这五类流量对 C&W 对抗攻击的敏感度不同, 对于表 4-4 所示的五类流量, 作为正常流量的 Normal 以及恶意攻击流量的 Probe attacks 相比之下对 C&W 对抗攻击较为不敏感。

对抽取的 500 个流量数据, 其准确率随着迭代次数变化、时间消耗随着迭代次数变化、以及 L2 距离随着时间变化如图 4-13, 图 4-14, 图 4-15 所示。




图 4-13 准确率随迭代次数变化




图 4-14 时间消耗随迭代次数变化




图 4-15 L2 距离随迭代次数变化

如图 4-13、图 4-14、图 4-15 可以发现上述三个评价指标都随着迭代次数变化而线性变化，上述结果表明 C&W 攻击可以选择更大的迭代次数，从而消耗更长的时间进而获得更好的攻击效果，当然随之而来的就是时间成本的增加。为进一步发现规律，在上述其他情况不变，单独变动迭代次数，从而观察不同类别的攻击成功率。如图所示 4-16 所示，随着迭代次数的增加，正常流量、Dos、u2r、R2L、Probe attacks 这五类流量攻击成功率。这里的攻击成功率值得是对于入侵检测模型 A，A 将该类的流量数据识别错误。




图 4-16 各类流量攻击成功率变化

通过图 4-16 可以发现：R2L 攻击成功率一直处于很高状态，这说明从一开始该类恶意流量就被 C&W 方案轻易的修改后绕过了入侵检测模型，u2r 类的恶意流量后来居上，一开始并没有受到 C&W 影响过多，但是随着迭代次数变化其也能绕过入侵检测模

型。Dos 类型的恶意流量在迭代到后期才逐渐能够绕过入侵检测模型。而 Probe attacks 方案则一直对 C&W 对抗方案不敏感。上述结果指导攻击者可以在短期时间内使用 R2L 类恶意流量结合 C&W 方案来促使 R2L 攻击绕过入侵检测系统。如果有充足时间来修改恶意流量，则可以进一步考虑 u2r 和 Dos 这两类方案。但是根据上述结果不建议使用 Probe attacks 恶意流量来进行实施对抗流量。

4.4.3 迭代白盒对抗攻击在流量数据中的表现

本节通过对比了 C&W、PGD 以及 SLIDE 三种迭代方案来对比所述方法在不同的评价指标上的表现。对比了 L2 距离，攻击成功率，以及创建时间，以迭代次数为自变量。

本节设定单次扰动为 0.1，其中 SLIDE 方案使用 L1 范数约束扰动，并限制稀疏度参数 λ 为 5，PGD 使用 L2 范数约束扰动，限制最大扰动不变，对于随着迭代次数增加的攻击成功率，C&W 方案和 PGD、和 SLIDE 对比如图 4-17 所示。有关 C&W 的有关参数参照 4.5.1 节不变。




图 4-17 不同攻击方案攻击成功率

从上图可以发现 C&W 和 SLIDE 方案在上述的给定参数下在迭代效果上不断地上升没有出现瓶颈，而 PGD 出现了瓶颈这是因为此处固定了 PGD 方案中的一个重要参数最大扰动，这是规定最大扰动距离，实际上在此继续实验发现大致在第 21 次 PGD 的攻击成功率基本不再发生变化。上述结果表明，单独考虑攻击成功率，C&W 强于其他两种方案。

在此基础上继续测试时间成本，如图 4-18 所示。




图 4-18 不同攻击方案时间成本

发现时间成本开销对于上述三个方案都几乎是线性的，但是对于上述三个方案的时间开销随着迭代次数增加的速度不一样，可以发现 C&W 对应的曲线斜率 K_1 ，SLIDE 曲线斜率 K_2 ，PGD 曲线斜率 K_3 ，存在以下关系， $K_1 > K_2 > K_3$ ，即 C&W 随着迭代次数增加的时间开销最大。

L2 距离是衡量真实流量和扰动后流量的欧式距离，这是衡量流量是否严重失真的重要标志，有关各攻击的 L2 距离如图 4-19 所示。




图 4-19 不同攻击方案 L2 距离

由于在前期规定了 PGD 扰动上限，在此发现 PGD 一直都在进行最大幅度的扰动（迭代过程中 L2 距离几乎不发生变化），在第 21 次迭代后攻击成功率不变化说明应该达到了这 500 流量的 PGD 方案上限，上图攻击成功率实验佐证了这一点。

4.4.4 白盒攻击迁移到黑盒模型上的表现

本节验证 MSM 框架的有效性，对于某一种对抗攻击方案的效果可能不同，因此试验了不同数据集、不同的决策流模型充当的黑盒模型、不同的白盒对抗攻击方案。

实验中, 本节测试了 FGM, PGD, L1 稀疏下降(SLIDE, sparse_l1_descent), C&W 这四种攻击方案分别在 MSM 黑盒对抗攻击威胁框架中的效果, 同时将充当黑盒模型方案拓展到 xgboost(Extreme Gradient Boosting)以及梯度提升决策树(Gradient Boosting Decision Tree,GBDT)来测试本方案。

在此规定每个数据集完全随机的抽取一部分的数据, 分别使用上述四种方案来攻击五层的 MLP。该 MLP 是通过迭代训练到的最后一次的代理模型, 可以看作是攻击者在规定时间内获取的和黑盒模型决策能力最相似的方案。在 NSL_KDD 设计的方案中, 随机抽取了 743 条流量数据作为最终的攻击成功率测试集, 在 UNSW-NB15 中抽取了 1289 条流量数据。

对于攻击者首先通过白盒攻击方案对代理模型进行攻击。在实验中, 对上述四类白盒攻击方案参数进行了如下设定: 对于 FGM, 规定扰动为 1, 使用 L2 正则化处理扰动; 对于 PGD, 每次迭代步长为 0.1, 迭代 10 次, 使用 L2 正则化处理扰动; 对于 C&W, 采用无目标攻击方案, 迭代 50 次; 对于 SLIDE, 每次迭代步长为 0.1, 迭代 10 次。

有关于上述涉及白盒对抗攻击方案在不同数据集和黑盒模型中的 L2 距离以及攻击创建时间如表 4-5 以及表 4-6 所示:

表 4-5 不同分类器、数据集、攻击方案生成时间对比

充当黑盒模型的分类器	数据集	FGM	PGD	C&W	SLIDE
Tabnet	NSL-KDD	2.8574s	15.9105s	399.9479s	11.2046s
	UNSW-NB15	3.3994s	22.3182s	538.2487s	14.2991s
xgboost	NSL-KDD	2.3810s	12.9645s	366.7340s	9.2364s
	UNSW-NB15	3.2898s	21.8108s	601.4314s	14.6113s
GBDT	NSL-KDD	2.5968s	14.7879s	398.6379s	13.0484s
	UNSW-NB15	3.7029s	23.2237s	736.1961s	16.4861s

对于不同的对抗攻击方案, 其攻击生成的时间不同, 对于同一个数据集和分类器以及不同的攻击方式来看, 相同的迭代次数下 (FGM 不参与迭代) C&W 的生成时间最长, 其次是 PGD 方案以及 SLIDE 方案, 最后是 FGM, 这是根据白盒方案不同的攻击原理所致。对于同一种对抗攻击方案和分类器, 不同数据集来看, UNSW-NB15 数据集比 NSL-KDD 数据集对抗攻击的生成时间更长, 这主要是因为是在预处理过程中, UNSW-NB15 和 NSL-KDD 的维数不同, 因此依赖于前向求导的对抗攻击所消耗的时间也不同。对于同一种攻击方式和数据集, 不同的黑盒分类器模型来看, xgboost 比 GBDT 消耗时间短, 而 GBDT 比 Tabnet 更短, 这主要和不同模型的推理速度有关, 实

上是由于 xgboost 有着更快的推理速度导致的。

表 4-6 不同分类器、数据集、攻击方案保真度对比

充当黑盒模型的分器	数据集	FGM	PGD	C&W	SLIDE
Tabnet	NSL-KDD	21.27	206.69	83.68	130.67
	UNSW-NB15	24.13	279.55	156.41	160.35
xgboost	NSL-KDD	22.24	207.07	101.60	129.62
	UNSW-NB15	28.84	278.86	120.40	138.42
GBDT	NSL-KDD	21.85	206.71	79.65	113.95
	UNSW-NB15	28.67	278.91	115.90	136.29

上述结果表明，即使给 C&W 更多的迭代次数，其 L2 距离值也小于其他两种迭代的对抗攻击方案，在这个衡量标准上，具有更高的真实程度。但是即使给定同样的迭代次数，其生成时长都是：C&W>PGD>SLIDE>FGM。因此考虑时间成本，可以使用 SLIDE 方案。

在上述 NSL-KDD 数据集、UNSW-NB15 数据集分别随机抽取的 743、1289 条流量中，在代理模型 MLP 上的攻击成功率以及迁移到目前模型上的攻击成功率如表 4-7 所示：

表 4-7 不同分类器、数据集、攻击方案攻击成功率及其迁移后对比

充当黑盒模型的分器	数据集	对 MLP 的白盒攻击成功率(%)				迁移后的攻击成功率(%)			
		FGM	PGD	C&W	SLIDE	MSM+ FGM	MSM+ PGD	MSM+ C&W	MSM+ SLIDE
Tabnet	NSL-KDD	17.76	28.12	62.58	60.29	14.05	51.68	31.49	50.33
	UNSW-NB15	14.68	19.80	84.20	63.02	11.50	20.97	17.55	45.56
xgboost	NSL-KDD	11.96	23.93	66.60	58.93	16.13	46.68	29.72	42.51
	UNSW-NB15	23.23	32.54	84.60	52.09	24.01	32.54	29.82	31.69
GBDT	NSL-KDD	19.32	36.96	67.24	44.76	5.73	43.59	16.36	36.01
	UNSW-NB15	19.68	25.96	87.31	46.91	19.99	37.21	32.71	52.18

上述结果表明，对于直接攻击 MLP 的白盒对抗攻击，C&W 无论在上述哪一个通过黑盒模型的分器所创建的代理模型 MLP 都是最强的。但是迁移到对应的黑盒模型上，其攻击成功率大打折扣，反而是通过迭代的 SLIDE 以及 PGD 方案成为了强势方。这应该黑盒模型与代理模型的决策边界存在差距有关，也有可能是 PGD 方案失真太严重导致，本方案训练的代理模型在限制训练数据后只能通过数据增强方案解决欠拟合

问题，通过不断的访问黑盒模型接口来模拟知识蒸馏（小模型通过来自大模型标签以求大模型能力），故而无法做到与黑盒模型完全相同的决策边界，而近似的决策边界对于代理模型方案的对抗攻击的迁移性非常重要^[18]，同时上述本章所述的白盒对抗攻击方案也没有引入动量项或是攻击中间层等影响对抗攻击迁移性行为，因此本文认为这种决策边界的差异性以及部分对抗攻击方案产生的流量数据失真情况严重是上述影响对抗攻击迁移效果的主要原因。

4.5 本章小结

本章通过四种白盒对抗攻击方案产生对抗流量，通过 t-SNE 可视化对抗流量数据和原始流量数据的低维表达，验证网络流量不同类型流量对对抗攻击方案敏感度，对比不同对抗攻击方案的评价指标，测试通过 MSM 迁移后的表现，经过本章实验发现总结如下：

1.t-SNE 低维可视化结果显示不参与迭代的 FGM 产生的对抗流量和原始数据最为相似，其次是 C&W、SILDE、PGD 对抗攻击方案，通过 t-SNE 展示了直观的效果。

2.验证了不同类型流量数据与对抗攻击的敏感度，以 C&W 为例，在少量迭代次数下，R2L>Normal>u2r>Probe attack≈Dos。在迭代次数多的情况下，u2r>R2L>Dos>Normal>Probe attack。

3.对于三种迭代的对抗攻击白盒情境中的表现，C&W 的攻击成功率以及保真度都表现出最优。

4.上述对抗攻击方案在 MSM 威胁方案迁移后，PGD 以及 SILDE 两种迭代对抗攻击方案的攻击成功率更佳。

第5章 总结与展望

5.1 总结

随着互联网的发展，网络安全问题日益突出。在当今数字化时代，网络攻击已成为企业、政府和个人面临的严重威胁。现今的网络攻击手法变化多端，包括但不限于零日漏洞利用、社会工程学攻击、勒索软件和 DDoS 攻击等。这些新型攻击方式往往具有高度的隐蔽性和变异性，使得传统的检测方法逐渐失效。为了更好地应对这些威胁，网络安全领域正积极推动网络攻击流量检测技术的智能化发展。智能化的检测技术通过引入机器学习、深度学习等先进技术，能够自动学习和识别新型威胁，实现对恶意流量的准确和及时检测。但是逐渐依赖上述先进技术的入侵检测方案，也和通用的领域一样容易受到对抗攻击的威胁，因此讨论对抗攻击的安全性迫在眉睫。

本文旨在探讨网络安全的重要性及其挑战，在入侵检测的背景中讨论对抗攻击生成的对抗流量问题，总结如下：

（1）针对传统基于几何以及雅可比矩阵等方案的数据增强方案不适用问题，提出了使用 mixup 进行数据增强方案来辅助代理模型的生成，在模型训练时间以及模型的推理能力上表现良好，该方案可以避免极端的特征边界值聚集情况带来的越界问题。

（2）针对现有的应用于入侵检测的黑盒对抗攻击相关方案不足，提出了 MSM 对抗攻击黑盒威胁方案，通过应用 mixup 方案对本地生成一个代理模型，以攻击代理模型生成对抗流量，进一步迁移到待攻击的黑盒模型上，进而根据对抗攻击的迁移性实施黑盒的对抗攻击，实验表明该方案的有效性。

（3）根据已有的相关对抗攻击方案，设计了对抗流量实施的技术手段，本文工作中，采用了 FGM、PGD、SILDE、C&W 四种方案来实施对抗攻击以产生对抗流量，进一步在第四章中使用 MSM 黑盒威胁方案中迁移了它们，相关实验表明白盒情境下的对抗攻击方案所得结论与图像领域一般性结论一致，然而通过迁移对抗攻击后发现对抗攻击的攻击有效性与白盒情境下的结论不一致。

（4）通过 t-SNE 方案可视化对抗流量，通过直观的角度发掘不同类型的对抗流量在低维空间的表示。实验表明，t-SNE 对抗流量的低维表达中，对抗攻击保真度衡量标准与可视化结果结论一致。

5.2 未来展望

本文对入侵检测中的对抗攻击迁移性进行研究，针对目前基于迁移性部署对抗攻击的方案对于流量数据较为不适用，提出了 MSM 网络流量黑盒对抗攻击威胁模型，对现有对抗攻击方案进行了评估，然而网络流量数据实施对抗攻击还有许多不足之处，主要体现在以下几个方面。

（1）大多数有关于对抗攻击方案的表现图像领域的基本结论和入侵检测基本一致，但是对于模型迁移前后的攻击成功率则并不完全一致，该现象值得继续探索。

（2）考虑到科学技术的落地性，目前有关对抗攻击在入侵检测中的实施，还需要技术人员许多努力。有关网络协议的规范有许多，特征空间的流量数据并不能真实的指导数据包的修改来实施真正的对抗攻击。

（3）对网络流量实施对抗攻击，如何进一步提升其迁移性是一项重要任务，后续工作应当为对抗攻击提升迁移性方案进一步讨论。

参考文献

- [1] 中国互联网络信息中心.第 52 次中国互联网络发展状况统计报告[EB\OL].中国互联网络信息中心, <https://www.cnnic.cn/NMediaFile/2023/0908/MAIN1694151810549M3LV0UWOAV.pdf>.
- [2] Sworna Z T, Mousavi Z, Babar M A. NLP methods in host-based intrusion detection Systems: A systematic review and future directions[J]. Journal of Network and Computer Applications, 2023: 103761.
- [3] Arthur M P, Kannan K. Cross-layer based multiclass intrusion detection system for secure multicast communication of MANET in military networks[J]. Wireless Networks, 2016, 22: 1035-1059.
- [4] Zhang Y, Zhu D, Wang M, et al. A comparative study of cyber security intrusion detection in healthcare systems[J]. International Journal of Critical Infrastructure Protection, 2024, 44: 100658.
- [5] Nandy T, Noor R M, Kolandaisamy R, et al. A review of security attacks and intrusion detection in the vehicular networks[J]. Journal of King Saud University-Computer and Information Sciences, 2024: 101945.
- [6] Nguyen D T, Le K H. The robust scheme for intrusion detection system in internet of things[J]. Internet of Things, 2023, 24: 100999.
- [7] Qian G, Hu L, Zhang W, et al. A new intrusion detection model for industrial control system based on hierarchical interval-based BRB[J]. Intelligent Systems with Applications, 2023, 18: 200239.
- [8] Wu S X, Banzhaf W. The use of computational intelligence in intrusion detection systems: A review[J]. Applied soft computing, 2010, 10(1) : 1-35.
- [9] Szegedy C, Zaremba W, Sutskever I, et al. Intriguing properties of neural networks[J]. arxiv preprint arxiv:1312.6199, 2013.
- [10] Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples[J]. arxiv preprint arxiv:1412.6572, 2014.
- [11] Qiu S, Liu Q, Zhou S, et al. Review of artificial intelligence adversarial attack and defense technologies[J]. Applied Sciences, 2019, 9(5) : 909.
- [12] Huang L, Joseph A D, Nelson B, et al. Adversarial machine learning[C]//Proceedings of the 4th ACM workshop on Security and artificial intelligence. 2011: 43-58.
- [13] Carlini N, Wagner D. Towards evaluating the robustness of neural networks[C]//2017 IEEE symposium on security and privacy. IEEE, 2017: 39-57.
- [14] Raghunath B R, Mahadeo S N. Network intrusion detection system (NIDS)[C]//2008 First International Conference on Emerging Trends in Engineering and Technology. IEEE, 2008: 1272-1277.
- [15] Wu J, Li J, Ji X. Security for cyberspace: challenges and opportunities[J]. Frontiers of Information Technology & Electronic Engineering, 2018, 19: 1459-1461.
- [16] Li S, Neupane A, Paul S, et al. Adversarial perturbations against real-time video classification systems[J]. arxiv preprint arxiv:1807.00458, 2018.

- [17] Li J, Ji S, Du T, et al. Textbugger: Generating adversarial text against real-world applications[J]. arxiv preprint arxiv:1812.05271, 2018.
- [18] Šrندیć N, Laskov P. Practical evasion of a learning-based classifier: A case study[C]//2014 IEEE symposium on security and privacy. IEEE, 2014: 197-211.
- [19] Rigaki M. Adversarial deep learning against intrusion detection classifiers[J]. 2017.
- [20] Clements J, Yang Y, Sharma A A, et al. Rallying adversarial techniques against deep learning for network security[C]//2021 IEEE Symposium Series on Computational Intelligence. IEEE, 2021: 01-08.
- [21] Yang K, Liu J, Zhang C, et al. Adversarial examples against the deep learning based network intrusion detection systems[C]//MILCOM 2018-2018 IEEE military communications conference. IEEE, 2018: 559-564.
- [22] Anderson J P. Computer security threat monitoring and surveillance[J]. Technical Report, James P. Anderson Company, 1980.
- [23] Hamed T, Dara R, Kremer S C. Network intrusion detection system based on recursive feature addition and bigram technique[J]. computers & security, 2018, 73: 137-155.
- [24] Bace R. An introduction to intrusion detection & assessment[J]. ICSA intrusion detection systems consortium white paper, 1999: 1-38.
- [25] Staniford-Chen S, Tung B, Porras P, et al. The common intrusion detection framework-data formats[J]. 1998.
- [26] Arpit D, Jastrzębski S, Ballas N, et al. A closer look at memorization in deep networks[C]//International conference on machine learning. PMLR, 2017: 233-242.
- [27] Gilmer J, Metz L, Faghri F, et al. Adversarial spheres[J]. arxiv preprint arxiv:1801.02774, 2018.
- [28] Madry A, Makelov A, Schmidt L, et al. Towards deep learning models resistant to adversarial attacks[J]. arxiv preprint arxiv:1706.06083, 2017.
- [29] Papernot N, McDaniel P, Jha S, et al. The limitations of deep learning in adversarial settings[C]//2016 IEEE European symposium on security and privacy (EuroS&P). IEEE, 2016: 372-387.
- [30] Moosavi-Dezfooli S M, Fawzi A, Frossard P. Deepfool: a simple and accurate method to fool deep neural networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016:2574-2582.
- [31] Wang Z. Deep learning-based intrusion detection with adversaries[J]. IEEE Access, 2018, 6:38367-38384.
- [32] Klambauer G, Unterthiner T, Mayr A, et al. Self-normalizing neural networks[J]. Advances in neural information processing systems, 2017, 30.
- [33] Chen P Y, Zhang H, Sharma Y, et al. Zoo: Zeroth order optimization based black-box attacks to deep neural networks without training substitute models[C]//Proceedings of the 10th ACM workshop on artificial intelligence and security. 2017: 15-26.
- [34] Lin Z, Shi Y, Xue Z. Idsgan: Generative adversarial networks for attack generation against intrusion detection[C]//Pacific-asia conference on knowledge discovery and data mining. Cham: Springer International Publishing, 2022: 79-91.

- [35] Arjovsky M, Chintala S, Bottou L. Wasserstein generative adversarial networks[C]//International conference on machine learning. PMLR, 2017: 214-223.
- [36] Sheffey S, Aderholdt F. Improving meek with adversarial techniques[C]//9th USENIX Workshop on Free and Open Communications on the Internet (FOCI 19). 2019.
- [37] Roshan K, Zafar A, Haque S B U. Untargeted white-box adversarial attack with heuristic defence methods in real-time deep learning based network intrusion detection system[J]. Computer Communications, 2024, 218: 97-113.
- [38] 杨怡,张兴兰.面向入侵检测的频域对抗攻击[J].计算机技术与发展,2023,33(09): 72-77.
- [39] 何昀峰,王小戈,刘路希等.基于注意力机制的入侵检测生成对抗网络模型[J].计算机应用,2022,42(S1): 152-159.
- [40] 郭瑶瑶. 面向入侵检测的深度学习对抗攻击方法研究[D]. 哈尔滨工程大学, 2020.
- [41] 吴金涛. 基于可逆对抗特征的网络入侵检测算法黑盒攻击与防御研究[D].杭州电子科技大学,2023.
- [42] 陈思然,吴敬征,凌祥,等.面向漏洞检测模型的强化学习式对抗攻击方法[J/OL].软件学报:1-21[2024-05-28].
- [43] Rahul-Vigneswaran K, Poornachandran P, Soman K P. A compendium on network and host based intrusion detection systems[C]//ICDSMLA 2019: Proceedings of the 1st International Conference on Data Science, Machine Learning and Applications. Springer Singapore, 2020: 23-30.
- [44] Bridges R A, Glass-Vanderlan T R, Iannacone M D, et al. A survey of intrusion detection systems leveraging host data[J]. ACM Computing Surveys, 2019, 52(6) : 1-35.
- [45] Agarwal R, Joshi M V. PNrule: a new framework for learning classifier models in data mining (a case-study in network intrusion detection)[C]//Proceedings of the 2001 SIAM International Conference on Data Mining. Society for Industrial and Applied Mathematics, 2001: 1-17.
- [46] Porras P A, Kemmerer R A. Penetration state transition analysis: A rule-based intrusion detection approach[C]//Proceedings Eighth Annual Computer Security Application Conference. IEEE Computer Society, 1992:220-229.
- [47] Sheu T F, Huang N F, Lee H P. NIS04-6:A time-and memory-efficient string matching algorithm for intrusion detection systems[C]//IEEE Globecom 2006. IEEE, 2006: 1-5.
- [48] Pan Z S, Lian H, Hu G Y, et al. An integrated model of intrusion detection based on neural network and expert system [C]//17th IEEE International Conference on Tools with Artificial Intelligence. IEEE, 2005: 2 pp.-672.
- [49] Komviriyavut T, Sangkatsanee P, Wattanapongsakorn N, et al. Network intrusion detection and classification with decision tree and rule based approaches[C]//2009 9th International Symposium on Communications and Information Technology. IEEE, 2009:1046-1050.
- [50] Sinapiromsaran K, Techaval N. Network intrusion detection using multi-attributed frame decision tree[C]//2012 Second International Conference on Digital Information and Communication Technology and it's Applications. IEEE, 2012:203-207.

-
- [51] 任家东, 刘新倩, 王倩等. 基于 KNN 离群点检测和随机森林的多层入侵检测方法[J]. 计算机研究与发展, 2019, 56(03): 566-575.
 - [52] 夏景明, 李冲, 谈玲等. 改进的随机森林分类器网络入侵检测方法[J]. 计算机工程与设计, 2019, 40(8): 2146-2150.
 - [53] Nuo Y. A novel selection method of network intrusion optimal route detection based on naive Bayesian[J]. International journal of applied decision sciences, 2018, 11(1) : 1-17.
 - [54] Ren X K, Jiao W B, Zhou D. Intrusion detection model of weighted naive bayes based on particle swarm optimization algorithm[J]. Computer Engineering and Applications, 2016, 52(7) : 122-126.
 - [55] Xiao L, Chen Y, Chang C K. Bayesian model averaging of Bayesian network classifiers for intrusion detection[C]//2014 IEEE 38th International Computer Software and Applications Conference Workshops. IEEE, 2014: 128-133.
 - [56] Xu J, Shelton C R. Intrusion detection using continuous time Bayesian networks[J]. Journal of Artificial Intelligence Research, 2010, 39: 745-774.
 - [57] Zong B, Song Q, Min M R, et al. Deep autoencoding gaussian mixture model for unsupervised anomaly detection[C]//International conference on learning representations. 2018.
 - [58] Yao R, Liu C, Zhang L, et al. Unsupervised anomaly detection using variational auto-encoder based feature extraction[C]//2019 IEEE International Conference on Prognostics and Health Management. IEEE, 2019: 1-7.
 - [59] Mirsky Y, Doitshman T, Elovici Y, et al. Kitsune: an ensemble of autoencoders for online network intrusion detection[J]. arXiv preprint arXiv:1802.09089, 2018.
 - [60] Gamage S, Samarabandu J. Deep learning methods in network intrusion detection: A survey and an objective comparison[J]. Journal of Network and Computer Applications, 2020, 169: 102767.
 - [61] Roy B, Cheung H. A deep learning approach for intrusion detection in internet of things using bi-directional long short-term memory recurrent neural network[C]//2018 28th international telecommunication networks and applications conference . IEEE, 2018: 1-6.
 - [62] Mirza A H, Cosan S. Computer network intrusion detection using sequential LSTM neural networks autoencoders[C]//2018 26th signal processing and communications applications conference . IEEE, 2018:1-4.
 - [63] Khan M A, Karim M R, Kim Y. A scalable and hybrid intrusion detection system based on the convolutional-LSTM network [J]. Symmetry, 2019, 11(4) : 583.
 - [64] Papernot N, McDaniel P, Goodfellow I, et al. Practical black-box attacks against machine learning[C]//Proceedings of the 2017 ACM on Asia conference on computer and communications security. 2017:506-519.
 - [65] Papernot N, McDaniel P, Goodfellow I. Transferability in machine learning: from phenomena to black-box attacks using adversarial samples[J]. arxiv preprint arxiv:1605.07277, 2016.
 - [66] Cheng S, Dong Y, Pang T, et al. Improving black-box adversarial attacks with a transfer-based prior[J]. Advances in neural information processing systems, 2019, 32.

-
- [67] Huang Z, Zhang T. Black-box adversarial attack with transferable model-based embedding[J]. arxiv preprint arxiv:1911.07140, 2019.
- [68] Brendel W, Rauber J, Bethge M. Decision-based adversarial attacks: Reliable attacks against black-box machine learning models[J]. arxiv preprint arxiv:1712.04248, 2017.
- [69] Cheng M, Le T, Chen P Y, et al. Query-efficient hard-label black-box attack: An optimization-based approach[J]. arxiv preprint arxiv:1807.04457, 2018.
- [70] Xie C, Zhang Z, Zhou Y, et al. Improving transferability of adversarial examples with input diversity[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019:2730-2739.
- [71] Zhou W, Hou X, Chen Y, et al. Transferable adversarial perturbations[C]//Proceedings of the European Conference on Computer Vision. 2018:452-467.
- [72] Zhang H, Cisse M, Dauphin Y N, et al. mixup: Beyond empirical risk minimization[J]. arxiv preprint arxiv:1710.09412, 2017.
- [73] Arik S Ö, Pfister T. Tabnet: Attentive interpretable tabular learning[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35(8) :6679-6687.
- [74] Tramer F, Boneh D. Adversarial training and robustness for multiple perturbations[J]. Advances in neural information processing systems, 2019, 32.